


MIDTERM


ข้อ 1.



Flow

1. CSV นำเข้า fileCSV เข้ามาเพื่อนำมาเป็นข้อมูล
2. String to number คือการเปลี่ยนตัวหนังสือให้อยู่ในรูปแบบของ Integer
3. Missing Value คือการเอา column ที่ไม่มีให้เปลี่ยนเป็น null เพื่อนำไปคำนวณต่อ
4. Group by คือการรวมกลุ่ม

Bar Chart



ขั้นตอนการวิเคราะห์

1. การนำเข้าไลบรารีและโหลดชุดข้อมูล

เริ่มต้นด้วยการนำเข้าไลบรารีที่จำเป็น เช่น pandas, numpy, matplotlib, seaborn และ scikit-learn เพื่อใช้ในการจัดการข้อมูล การวิเคราะห์ และการสร้างโมเดล จากนั้นทำการโหลดไฟล์ 2_Mall_Customers_Adj.csv เข้ามาในตัวแปร df และตั้งชื่อคอลัมน์ให้เหมาะสม ได้แก่:

- CustomerID
- Gender
- Age
- AnnualIncome
- SpendingScore

2. การเตรียมข้อมูลเบื้องต้น

เนื่องจากคอลัมน์ Gender เป็นข้อมูลแบบ string (Male/Female) จึงต้องถูกแปลงให้เป็นตัวเลข 0 และ 1 ด้วย LabelEncoder เพื่อให้สามารถใช้ในแบบจำลองได้

3. การวิเคราะห์ความสัมพันธ์เบื้องต้น

สร้าง **Correlation Matrix (Heatmap)** เพื่อดูความสัมพันธ์ระหว่างตัวแปรต่าง ๆ โดยใช้ sns.heatmap() พบว่า Annual Income และ Age มีความสัมพันธ์ในระดับหนึ่งกับ Spending Score ซึ่งบ่งชี้ว่าข้อมูลนี้สามารถนำมาใช้ในการทำนายได้

4. การแยก Features และ Target

เรากำหนด:

- X = ฟีเจอร์อิสระ ได้แก่ Gender, Age, AnnualIncome
- y = ตัวแปรเป้าหมาย คือ SpendingScore

5. การแบ่งข้อมูล Train/Test

ใช้ train_test_split() เพื่อแบ่งข้อมูลเป็น 80% สำหรับฝึกสอน และ 20% สำหรับทดสอบ เพื่อให้โมเดลสามารถประเมินประสิทธิภาพได้แม่นยำ

6. การทดลอง Polynomial Regression หลายระดับ (Degrees)

ทดลองสร้างโมเดล Polynomial Regression ที่มี degree ตั้งแต่ 1 ถึง 5 โดยใช้ PolynomialFeatures และ LinearRegression แล้ววัดผลด้วย **Mean Squared Error (MSE)** สำหรับชุดทดสอบ (Test set)

ในกรณีที่ $\text{degree} = 2$ ระบบจะแสดงค่าพยากรณ์ (y_{pred}) เทียบกับค่าจริง (y_{test}) และพิมพ์ค่าสัมประสิทธิ์ (coefficients) ของโมเดลออกมาเพื่อวิเคราะห์ว่าโมเดลเรียนรู้หรือไม่

7. การวิเคราะห์ผลลัพธ์ MSE

สร้างกราฟเปรียบเทียบค่าความคลาดเคลื่อน (MSE) ของแต่ละ degree เพื่อดูว่า degree ใดให้ผลดีที่สุด พบว่าเมื่อค่า MSE ต่ำสุด แสดงว่าโมเดลมีความสามารถในการทำนายได้แม่นยำที่สุด ณ degree นั้น

8. การเลือก Degree ที่เหมาะสมที่สุด

หลังจากวิเคราะห์ค่าความคลาดเคลื่อน ระบบจะเลือก degree ที่ให้ค่า MSE ต่ำที่สุด เพื่อใช้เป็นตัวแทนของโมเดลที่ดีที่สุดในการพยากรณ์

9. การวิเคราะห์ความสัมพันธ์ด้วย Pairplot

แสดงความสัมพันธ์ระหว่างทุกคอลัมน์ด้วย `sns.pairplot()` ซึ่งช่วยให้มองเห็นความสัมพันธ์เชิงเส้นและไม่เชิงเส้นระหว่างฟีเจอร์ต่าง ๆ ได้ อย่างชัดเจน

10. การแสดงผล Polynomial Regression

ใช้ฟีเจอร์เพียงตัวเดียวคือ `AnnualIncome` เพื่อสร้างกราฟแสดงเส้น Polynomial Regression เปรียบเทียบกับข้อมูลจริง โดยใช้ degree ที่ดีที่สุด

ผลลัพธ์เป็นกราฟที่แสดง:



- จุดสีน้ำเงิน: ข้อมูลจริงของลูกค้า (รายได้กับคะแนนการใช้จ่าย)
- เส้นสีแดง: เส้นพยากรณ์ที่ได้จาก Polynomial Regression


กราฟนี้ช่วยให้เห็นว่าโมเดลสามารถจับแนวโน้มของข้อมูลได้ดีเพียงใด

สรุปผลการวิเคราะห์

จากการทดลองใช้ Polynomial Regression หลายระดับ พบว่า:

- โมเดล Polynomial Regression ที่มี degree ที่เหมาะสม สามารถทำนายค่า Spending Score ได้ใกล้เคียงค่าจริง
- การแสดงกราฟและค่า MSE ทำให้สามารถเลือกโมเดลที่มีประสิทธิภาพสูงสุด
- Annual Income เป็นฟีเจอร์ที่มีแนวโน้มสัมพันธ์กับ Spending Score อย่างชัดเจน
- ผลการวิเคราะห์สามารถนำไปใช้ในการแบ่งกลุ่มลูกค้า หรือทำ Customer Segmentation เพื่อวางกลยุทธ์การตลาดได้





```

    CustomerID  Gender  Age  AnnualIncome  SpendingScore
0             1      1   19             15           54.12
1             2      1   21             15           47.86
2             3      0   20             16           50.50
3             4      0   23             16           52.39
4             5      0   31             17           38.41

Correlation Matrix:
               CustomerID  Gender  Age  AnnualIncome  SpendingScore
CustomerID      1.000000  0.057400 -0.026763  0.977548  0.746587
Gender          0.057400  1.000000  0.060867  0.056410  0.016076
Age            -0.026763  0.060867  1.000000 -0.012398 -0.560406
AnnualIncome    0.977548  0.056410 -0.012398  1.000000  0.756499
SpendingScore   0.746587  0.016076 -0.560406  0.756499  1.000000
Degree 1: MSE = 22.62
Degree 2: MSE = 22.38

Polynomial Degree 2 Coefficients:
[ 0.00000000e+00  6.97376576e-01 -5.82471544e-01  4.76590413e-01
  6.97376576e-01 -9.95768457e-02  5.27770431e-02  9.63032092e-04
 -5.41339362e-04 -6.18554854e-04]
Intercept: 56.2207005227708

ตัวอย่างค่าทำนาย (y_pred) เทียบกับจริง (y_test):
   y_true  y_pred
0   69.37  70.556720
1   44.95  53.178234
2   37.57  34.509379
3   74.69  71.630815
4   53.23  52.926197
5   78.63  73.197824
6   57.82  59.187448
7   65.23  71.363635
8   68.91  63.208918
9   55.64  59.935600
Degree 3: MSE = 27.13
Degree 4: MSE = 29.44
Degree 5: MSE = 30.37

```

ข้อ 3

ขั้นตอนการวิเคราะห์

1. การนำเข้าไลบรารีและโหลดชุดข้อมูล

เริ่มต้นด้วยการนำเข้าไลบรารีที่จำเป็น เช่น `pandas`, `numpy`, และไลบรารีจาก `scikit-learn` ซึ่งใช้สำหรับสร้างโมเดล Machine Learning, การประเมินผล และการแสดงผล Confusion Matrix จากนั้นทำการโหลดไฟล์ `3_dataset_tafu_2000.csv` เพื่อใช้งานในการวิเคราะห์

2. การตรวจสอบข้อมูลเบื้องต้น

ตรวจสอบค่า missing (ค่าว่าง) ในแต่ละคอลัมน์ และตรวจสอบชนิดข้อมูล (dtype) เพื่อเตรียมความพร้อมก่อนการประมวลผล พบว่าข้อมูลบางส่วนอาจมี missing ซึ่งจำเป็นต้องจัดการก่อนฝึกสอน โมเดล

3. การจัดการ Missing Values

ข้อมูลที่มี missing ในคอลัมน์ตัวเลข จะถูกแทนที่ด้วย ค่ามัธยฐาน (median) ของแต่ละคอลัมน์ เพื่อรักษาค่ากลางของข้อมูลไว้โดยไม่ให้เกิดการเบี่ยงเบนมากนัก ซึ่งเป็นวิธีที่เหมาะสมในกรณีที่ข้อมูลมีการกระจายตัวไม่สมมาตร

4. การแปลง Label ให้เป็นตัวเลข

คอลัมน์ label ซึ่งใช้เป็นเป้าหมายในการทำนาย มีค่าที่เป็นตัวอักษร (ผ่าน/ไม่ผ่าน) จึงจำเป็นต้องแปลงเป็นตัวเลข (เช่น 0 = ไม่ผ่าน, 1 = ผ่าน) ด้วย LabelEncoder เพื่อให้สามารถใช้ในโมเดล Machine Learning ได้

5. การแยก Features และ Target

ชุดข้อมูลถูกแยกออกเป็น:

- **X** = ฟีเจอร์ที่ใช้ในการทำนาย (ข้อมูลจากเซนเซอร์)
- **y** = ตัวแปรเป้าหมาย (label)

6. การแบ่งข้อมูล Train/Test

ข้อมูลถูกแบ่งออกเป็น 2 ชุด ได้แก่:

- ชุด Train (80%) สำหรับฝึกสอนโมเดล
- ชุด Test (20%) สำหรับประเมินโมเดล

เพื่อให้การประเมินมีความน่าเชื่อถือ ไม่เกิด overfitting

7. การปรับขนาดข้อมูล (Standardization)

เพื่อให้ข้อมูลทุกฟีเจอร์มีสเกลใกล้เคียงกัน ระบบจะทำการปรับขนาดข้อมูลด้วย StandardScaler ซึ่งช่วยให้โมเดลทำงานได้มีประสิทธิภาพมากขึ้น โดยเฉพาะ SVM และ KNN ที่ไวต่อสเกลของข้อมูล

8. การฝึกสอนโมเดลหลายประเภท

มีการทดลองใช้โมเดล 4 ประเภท ได้แก่:

- **Logistic Regression:** โมเดลเชิงเส้นที่เหมาะสมกับปัญหา binary classification
- **Random Forest:** โมเดลแบบ ensemble ที่ใช้ decision trees หลายต้น
- **SVC (Support Vector Machine):** โมเดลที่หาขอบเขตการจำแนกที่ดีที่สุด

- **KNN (K-Nearest Neighbors):** โมเดลที่ใช้ระยะทางของจุดข้อมูลรอบข้างในการจำแนก

แต่ละโมเดลถูกฝึกสอนด้วยข้อมูลที่เตรียมไว้ และคำนวณค่าความแม่นยำ (Accuracy) จากชุดข้อมูลทดสอบ

9. การเลือกโมเดลที่ดีที่สุด

เมื่อได้ผลลัพธ์ของ Accuracy ของแต่ละโมเดลแล้ว จะมีการคัดเลือกเฉพาะโมเดลที่มี Accuracy มากกว่า **90%** จากนั้นเลือกโมเดลที่ดีที่สุดในกลุ่มดังกล่าว โดยอิงจากค่า Accuracy สูงสุด

10. การแสดงผลด้วย Confusion Matrix

โมเดลที่ดีที่สุดจะดูนามาวิเคราะห์เพิ่มเติมด้วย **Confusion Matrix** เพื่อดูว่าจำนวนตัวอย่างที่จำแนกถูก/ผิดมีกี่รายการ เช่น:


- **TP (True Positive):** จำแนกว่าผ่าน และจริงๆ ผ่าน
- **FP (False Positive):** จำแนกว่าผ่าน แต่จริงๆ ไม่ผ่าน
- **FN (False Negative):** จำแนกว่าไม่ผ่าน แต่จริงๆ ผ่าน
- **TN (True Negative):** จำแนกว่าไม่ผ่าน และจริงๆ ไม่ผ่าน

การแสดงผลนี้ช่วยให้เข้าใจว่าโมเดลมีข้อผิดพลาดอย่างไรบ้าง

ผลลัพธ์ที่ได้

- มีการเปรียบเทียบ Accuracy ของโมเดลทั้ง 4 แบบ
- มีอย่างน้อยหนึ่งโมเดลที่มี Accuracy > 90%
- แสดงผล Confusion Matrix ของโมเดลที่เลือก

หากไม่มีโมเดลใดมี Accuracy มากกว่า 90% จะมีข้อความแจ้งเตือนอัตโนมัติว่า “ไม่มีโมเดลใดที่ accuracy > 90%”



	CustomerID	Gender	Age	AnnualIncome	SpendingScore
0	1	1	19	15	54.12
1	2	1	21	15	47.86
2	3	0	20	16	50.50
3	4	0	23	16	52.39
4	5	0	31	17	38.41

Correlation Matrix:

	CustomerID	Gender	Age	AnnualIncome	SpendingScore
CustomerID	1.000000	0.057400	-0.026763	0.977548	0.746587
Gender	0.057400	1.000000	0.060867	0.056410	0.016076
Age	-0.026763	0.060867	1.000000	-0.012398	-0.560406
AnnualIncome	0.977548	0.056410	-0.012398	1.000000	0.756499
SpendingScore	0.746587	0.016076	-0.560406	0.756499	1.000000

Degree 1: MSE = 22.62

Degree 2: MSE = 22.38

Polynomial Degree 2 Coefficients:

```
[ 0.00000000e+00  6.97376576e-01 -5.82471544e-01  4.76590413e-01
  6.97376576e-01 -9.95768457e-02  5.27770431e-02  9.63032092e-04
 -5.41339362e-04 -6.18554854e-04]
```

Intercept: 56.2207005227708

ตัวอย่างค่าทำนาย (y_pred) เทียบกับจริง (y_test):

	y_true	y_pred
0	69.37	70.556720
1	44.95	53.178234
2	37.57	34.509379
3	74.69	71.630815
4	53.23	52.926197
5	78.63	73.197824
6	57.82	59.187448
7	65.23	71.363635
8	68.91	63.208918
9	55.64	59.935600

Degree 3: MSE = 27.13

Degree 4: MSE = 29.44

Degree 5: MSE = 30.37