




วิทยาการข้อมูลเบื้องต้น

Introduction to Data Science



ดำรงฤทธิ์ เศรษฐศิริโชค

วัตถุประสงค์

- ต้องการให้นักศึกษาเข้าใจหลักการของวิทยาการข้อมูล
 - หลักการ (Methodology)
 - เครื่องมือ (Tools)
 - กรณีศึกษา (Case Study)

คำอธิบายรายวิชา

“ความรู้วิทยาการข้อมูลเบื้องต้น ชนิดของข้อมูล แหล่งข้อมูล การรวบรวมข้อมูล คุณภาพข้อมูล การทำความสะอาดข้อมูล การสกัดข้อมูล การวิเคราะห์ข้อมูล แบบจำลองข้อมูล การสร้างมโนภาพข้อมูล”



ตำราและเอกสาร

- Clelen, D., Meysman, A.D.B., Ali, M. (2016). *Introducing Data Science, BIG DATA, MACHINE LEARNING, AND MORE, USING PYTHON TOOLS*. Manning Publications Co.
- Tan, P., Steinbach, M., Karpatne, A., Kumar, V. (2019). *Introduction to Data Mining (2nd ed.)*. New York: Pearson.



1. วิเคราะห์ข้อมูลเบื้องต้น

Introduction to Data Science

ดำรงคุณธิ์ เศรษฐศิริโชค

1. วิทยาการข้อมูลเบื้องต้น

- 1.1 แนะนำวิทยาการข้อมูล
- 1.2 วิทยาการข้อมูลกับคลังข้อมูลขนาดใหญ่
- 1.3 มุมมองข้อมูล
- 1.4 กระบวนการวิทยาการข้อมูล (Data Science Process)
- 1.5 การเรียนรู้ของเครื่อง (Machine Learning)
- 1.6 ธรรมาภิบาลข้อมูล (Data Government)
- 1.7 เครื่องมือ
- 1.8 กรณีศึกษา



1.1 แนะนำวิทยาการข้อมูล



2025 Top 10 Strategic Technology Trends



AI imperatives and risks

- Agentic AI
- AI Governance Platforms
- Disinformation Security



New frontiers of computing

- Post-Quantum Cryptography
- Ambient Invisible Intelligence
- Energy-Efficient Computing
- Hybrid Computing




Human-machine synergy

- Spatial Computing
- Polyfunctional Robots
- Neurological Enhancement

Source: Gartner
© 2024 Gartner, Inc. and/or its affiliates.
All rights reserved. 3185862

Gartner®

เป้าหมายการพัฒนาตามแนวโน้มเทคโนโลยีเชิงกลยุทธ์ที่สำคัญในช่วงปี 2022 – 2026



Gartner Predictions for Generative AI

Before long, GenAI will greatly impact product development, customer experience, employee productivity and innovation. We predict that:



By 2025, 70% of enterprises will identify the sustainable and ethical use of AI among their top concerns.



By 2025, 30% of outbound marketing messages from large organizations will be synthetically generated. That's up from less than 2% in 2022.



By 2030, AI could reduce global CO2 emissions by 5 to 15% and consume up to 3.5% of the world's electricity.



By 2025, 35% of large organizations will have a chief AI officer who reports to the CEO or COO.



Through 2026, despite all the advancements in AI, the impact on global jobs will be neutral — there will not be a net decrease or increase.



By 2030, decisions made by AI agents without human oversight will cause \$100 billion in losses from asset damage.



By 2025, the use of synthetic data will reduce the volume of real data needed for machine learning by 70%.



By 2033, AI solutions will result in more than half a billion net-new human jobs.


การคาดการณ์แนวโน้มสำคัญของ Generative AI ภายในปี 2025

- การกำกับดูแล AI อย่างมีจริยธรรม → 70% ขององค์กรจะให้ความสำคัญกับการใช้ AI อย่างยั่งยืนและมีจริยธรรม เป็นหนึ่งในประเด็นหลัก
- บทบาทของ Chief AI Officer → 35% ขององค์กรขนาดใหญ่จะมีตำแหน่ง Chief AI Officer (CAIO) ซึ่งจะรายงานตรงต่อ CEO
- ข้อมูลสังเคราะห์ (Synthetic Data) จะเข้ามามีบทบาทสำคัญ → ลดปริมาณข้อมูลจริงที่ต้องใช้ในการฝึก Machine Learning ลง 70%
- การตลาดที่ขับเคลื่อนโดย AI → 30% ของข้อความการตลาดที่ส่งออกจากองค์กรขนาดใหญ่ จะถูกสร้างขึ้นโดย AI (เพิ่มขึ้นจาก 2% ในปี 2022)



วิทยาศาสตร์ข้อมูลหรือความบังเอิญ (Coincidence)

- ทอยเหรียญให้ออกหัว
- ปล่อยแก้วหล่นจากความสูงต่างๆ → ตก/ไม่ตก
- ชู้ตลูกบาส → ลง/ไม่ลง



<https://www.mainstand.co.th/>

Data Science: The Sexiest Job in the 21st Century

- ปี 2014 New York Times รายงานรายได้นักวิทยาการข้อมูลเฉลี่ย \$112,000
- Walmart ใช้กลยุทธ์ crowd-sourcing กระจายการแก้ปัญหาสู่กลุ่มย่อย ส่งข้อมูลลง Kaggle เพื่อสร้างการแข่งขันการคิดค้นโปรโมชั่นและทำนายยอดขาย
- Massive open online courses (MOOC) Coursera, Udacity, edX เพิ่มคอร์สเรียนวิทยาการข้อมูลในขณะที่ยกเลิกข้อมูลทั้งหมด


วิทยาการข้อมูล คือ


- การใช้สหวิทยาการสร้างระเบียบวิธีและการประมวลผลในการวิเคราะห์ข้อมูลที่เป็นประโยชน์เพื่อให้ได้มาซึ่งองค์ความรู้ที่บรรจุอยู่ภายใน
- พัฒนาจากพื้นฐานสถิติและกระบวนการบริหารจัดการข้อมูล
- สร้างการวิเคราะห์และนำไปใช้งานด้วยเครื่องมือที่เหมาะสม
- สามารถเชื่อมโยงข้อมูลจากคลังข้อมูลขนาดใหญ่และหลากหลาย

“big data and data science as being like the relationship between crude oil and an oil refinery”

วิทยาการข้อมูลช่วยเพิ่มมูลค่าธุรกิจ

- เข้าใจสภาพแวดล้อม
- วิเคราะห์สาเหตุของปัญหา
- เผยโอกาสและช่องทางที่ซ่อนอยู่
- ความอยากรู้อยากเห็น
- หาข้อพิสูจน์
- พิจารณาและตัดสินใจ







Funko Pop! Star Wars: The Mandalorian - The Child Vinyl Bobblehead
 Visit the Funko Store
 ★★★★★ 11,565 ratings | 27 answered questions

Available from these sellers.

Size: 3.75 inches
 Color: Multicolor
 Brand: Funko
 Material: Vinyl
 Item Dimensions: 2.5 x 2.5 x 3.75 inches
 LxWxH
 Number of Pieces: 1

About this item

- From Star Wars: The Mandalorian is The Child as a stylized Pop! vinyl bobblehead from Funko!
- The Child has been retrieved from the compound, will you be his new caretaker?
- Stylized collectible stands approximately 3.25 inches tall, perfect for any Mandalorian or Star Wars fan!
- This figure is a bobblehead.
- Collect and display all The Mandalorian Pop! vinyl bobbleheads!
- This is the way.

New (124) from \$12.98 & FREE Shipping on orders over \$25.00
[Report incorrect product information.](#)



TUBBZ Spyro The Dragon Spyro Collectible Rubber Duck Figurine – Official Spyro The Dragon...
 ★★★★★ 153
 \$12.99

Sponsored

Roll over image to zoom in



Products related to this item
 Sponsored








Pop! Star Wars: The Mandalorian - 10 Inch
 Star Wars The Bounty Collection Series 2 The
 Star Wars The Bounty Collection Series 2 The
 Star Wars - The Mandalorian - The Child
 Star Wars The Child Talking Plush Toy with
 Star Wars The Bounty Collection Series 2 The



4 กลยุทธ์วิทยาการข้อมูล


1. Probing reality
2. Pattern discovery
3. Predicting future events
4. Understanding people and the world



<https://www.proprofs.com/>

กลยุทธ์วิทยาการข้อมูล: 1. Probing reality

- มองข้อมูลเป็นตัวแทนการกระทำที่เกิดขึ้นกับโลก
- การวิเคราะห์การตอบสนองทำให้ข้อมูลมีมูลค่าเพิ่มได้อย่างมาก และนำไปสู่การตัดสินใจกระทำการในสิ่งที่ตามมา
- ตัวอย่าง A/B Testing



<https://instapage.com/blog/personalized-experiences-vs-ab-testing/>

กลยุทธ์วิทยาการข้อมูล: 2. Pattern discovery

- วิธีดั้งเดิม Divide and conquer ยากต่อการตัดสินใจนำไปประยุกต์ใช้
- วิเคราะห์เพื่อค้นหารูปแบบที่มีประโยชน์ แบ่งกลุ่มข้อมูลอย่างเป็นธรรมชาติ จะทำให้ปัญหาง่ายขึ้น
- ตัวอย่าง Programmatic Advertising หรือ Digital Marketing



<https://www.everydaymarketing.co/media/what-is-programmatic-advertising/>

กลยุทธ์วิทยาการข้อมูล: 3. Predicting future events

- มองหาแบบจำลองข้อมูลที่เหมาะสมเพื่อทำนายข้อมูลอนาคต
- คำนึงถึงสภาพแวดล้อมที่ไม่แน่นอนตลอดเวลาเพื่อตีกรอบการวิเคราะห์ หลีกเลี่ยงปัญหาที่คาดเดาไม่ได้
- ตัวอย่าง การทำนายและวางแผนสำหรับพนักงานในร้านขายปลีก โดยใช้ข้อมูลอากาศ บันทึกการขาย สภาพการจราจร

กลยุทธ์วิทยาการข้อมูล: 4. Understanding people and the world

- สำคัญอย่างมาก และหลายบริษัทใหญ่และภาครัฐต้องลงทุนสูงเพื่อให้ได้มา
- เป้าหมายคือทำความเข้าใจสิ่งรอบตัวของผู้คน และอยู่บนพื้นฐานของวิทยาศาสตร์
 - natural language
 - computer vision
 - psychology
 - neuroscience
- คำนึงถึงกระบวนการจริงที่ขับเคลื่อนพฤติกรรม เพื่อตัดสินใจในสิ่งที่ดีที่สุด

ข้อใดเหมาะกับนักวิทยาการข้อมูล

- ❑ 1. ความอยากรู้อยากเห็น
- ❑ 2. สามารถเข้าใจสภาพแวดล้อม
- ❑ 3. สามารถพิจารณาหาข้อพิสูจน์และตัดสินใจได้
- ❑ 4. มีความสามารถด้านสถิติและโปรแกรมคอมพิวเตอร์

1.2 วิทยาการข้อมูลกับคลังข้อมูลขนาดใหญ่



คลังข้อมูลขนาดใหญ่คืออะไร


- Volume—How much data is there?
- Variety—How diverse are different types of data?
- Velocity—At what speed is new data generated?

veracity: How accurate is the data?

value: What is the benefits?

วิทยาการข้อมูลกับคลังข้อมูลขนาดใหญ่


- ในช่วงเวลาสั้นๆ
 - 2.5M Facebook contents
 - 4M Google searches
 - 200M Emails
 - 275K Tweets
- ข้อมูลคือหัวใจสำคัญ



แผนภาพคลังข้อมูลขนาดใหญ่


BIG DATA FLOW CHART

BASIC DIAGRAM




<https://www.coraline.co.th/single-post/2018/10/15/composition-of-data-systems>

โครงสร้างสถาปัตยกรรมข้อมูลสารสนเทศขนาดใหญ่



1.3 មុំមមទង់មម



มุมมองข้อมูล

- Log File
- E-mail
- Social media
- Sale Data
- Patient information file
- Sports performance
- Sensor
- Security Camera

Structured

Unstructured

Natural language

Machine-generated

Graph-based

Audio, video, and images

Streaming

ข้อมูลแบบมีโครงสร้าง (Structured)

- Database, Excel, SQL, Comma-Separated Values – CSV

Indicator ID	Dimension List	Timeframe	Numeric Value	Missing Value Flag	Confidence Inte
214390830	Total (Age-adjusted)	2008	74.6%		73.8%
214390833	Aged 18-44 years	2008	59.4%		58.0%
214390831	Aged 18-24 years	2008	37.4%		34.6%
214390832	Aged 25-44 years	2008	66.9%		65.5%
214390836	Aged 45-64 years	2008	88.6%		87.7%
214390834	Aged 45-54 years	2008	86.3%		85.1%
214390835	Aged 55-64 years	2008	91.5%		90.4%
214390840	Aged 65 years and over	2008	94.6%		93.8%
214390837	Aged 65-74 years	2008	93.6%		92.4%
214390838	Aged 75-84 years	2008	95.6%		94.4%
214390839	Aged 85 years and over	2008	96.0%		94.0%
214390841	Male (Age-adjusted)	2008	72.2%		71.1%
214390842	Female (Age-adjusted)	2008	76.8%		75.9%
214390843	White only (Age-adjusted)	2008	73.8%		72.9%
214390844	Black or African American only (Age-adjusted)	2008	77.0%		75.0%
214390845	American Indian or Alaska Native only (Age-adjusted)	2008	66.5%		57.1%
214390846	Asian only (Age-adjusted)	2008	80.5%		77.7%
214390847	Native Hawaiian or Other Pacific Islander only (Age-adjusted)	2008	DSU		
214390848	2 or more races (Age-adjusted)	2008	75.6%		69.6%

ข้อมูลแบบกึ่งโครงสร้าง (Semi-structured)

- มีการนิยามโครงสร้างของข้อมูลไว้ แต่โครงสร้างเป็นแบบลำดับชั้น (Hierarchy) แผนภูมิต้นไม้
- Extensible Markup Language – XML
- JavaScript Object Notation – JSON

```
{
  "name": "City Zoo",
  "animal":
    [
      {"type": "Reptile", "species": "crocodile"},
      {"type": "Bird", "species": "crowned pigeon"},
      {"type": "Mammal", "species": "giraffe"}
    ]
}
```

ข้อมูลแบบไม่มีโครงสร้าง (Unstructured)

- รูปแบบหลากหลาย
- ภาษามนุษย์ (Natural Language)
- ข้อความ รูปภาพ เสียง วิดีทัศน์



ข้อมูลที่ถูกสร้างขึ้น (Machine-generated)


- ถูกสร้างขึ้นแบบอัตโนมัติจากระบบ
- web server logs, call detail records, network event logs
- The internet of things

```
CSIPERF:TXCOMMIT;313236
2014-11-28 11:36:13, Info
69), objectname [6]"(null)"
2014-11-28 11:36:13, Info
result 0x00000000, handle @0x4e54
2014-11-28 11:36:13, Info
Beginning NT transaction commit...
2014-11-28 11:36:13, Info
trace:
CSIPERF:TXCOMMIT;273983
2014-11-28 11:36:13, Info
70), objectname [6]"(null)"
2014-11-28 11:36:13, Info
result 0x00000000, handle @0x4e5c
2014-11-28 11:36:13, Info
Beginning NT transaction commit...
2014-11-28 11:36:14, Info
trace:
CSIPERF:TXCOMMIT;386259
2014-11-28 11:36:14, Info
71), objectname [6]"(null)"
2014-11-28 11:36:14, Info
result 0x00000000, handle @0x4e5c
2014-11-28 11:36:14, Info
Beginning NT transaction commit...
2014-11-28 11:36:14, Info
trace:
CSIPERF:TXCOMMIT;375581
```


```
CSI 00000153 Creating NT transaction (seq
CSI 00000154 Created NT transaction (seq 69)
CSI 00000155@2014/11/28:10:36:13.471
CSI 00000156@2014/11/28:10:36:13.705 CSI perf
CSI 00000157 Creating NT transaction (seq
CSI 00000158 Created NT transaction (seq 70)
CSI 00000159@2014/11/28:10:36:13.764
CSI 0000015a@2014/11/28:10:36:14.094 CSI perf
CSI 0000015b Creating NT transaction (seq
CSI 0000015c Created NT transaction (seq 71)
CSI 0000015d@2014/11/28:10:36:14.106
CSI 0000015e@2014/11/28:10:36:14.428 CSI perf
```

ข้อมูลที่ถูกสร้างขึ้น (Machine-generated)

- The internet of things




SMART STADIUMS



Graph-based หรือข้อมูลเชื่อมโยงเป็นเครือข่าย


- ข้อมูลที่สนใจความเชื่อมโยงความสัมพันธ์และความใกล้ชิดกัน
- เก็บบันทึกและแสดงออกมาในรูปแบบกราฟได้
- ตัวอย่างข้อมูลเช่น เครือข่ายสังคมออนไลน์ ความสนใจภาพยนตร์ Netflix เครื่องมือ SPARQL, GraphDB เป็นต้น





ตัวอย่างความเชื่อมโยงของเพื่อนบนเครือข่ายสังคมออนไลน์

ข้อมูลภาพ เสียง วิดีโอ

- ข้อมูลที่มีความท้าทายสูง
- ปริมาณข้อมูลจำนวนมาก



ตัวอย่างการวัดประสิทธิภาพหรือโอกาสการทำประตู
ของผู้เล่นโดยใช้ข้อมูลภาพ ระยะทาง ความเร็ว มุม



ข้อมูลที่ไหลต่อเนื่อง (Streaming data)


- ข้อมูลที่ถูกสร้างขึ้นอย่างต่อเนื่องในรูปแบบใดๆ
- ความสำคัญอยู่ที่การจัดการกระบวนการเพื่อรองรับให้ทันกับข้อมูลเข้า
- ตัวอย่างเช่น
 - ความนิยมบน Twitter
 - ข้อมูลตลาดหุ้น
 - ข้อมูลการแสดงสด

1.4 กระบวนการวิทยาการข้อมูล



กระบวนการวิทยาการข้อมูล

1. การกำหนดเป้าหมายวิจัย
2. การเก็บข้อมูล
3. การเตรียมข้อมูล
4. การสำรวจข้อมูล
5. การสร้างแบบจำลองข้อมูล
6. การนำเสนอผลลัพธ์และ
วางขบวนการอัตโนมัติ



กระบวนการวิทยาการข้อมูล

1. การกำหนดเป้าหมายวิจัย
 - มองประโยชน์ที่จะได้รับ
 - ข้อมูลและทรัพยากรที่ต้องใช้
 - ระยะเวลาและการส่งมอบ
2. การเก็บข้อมูล
 - เก็บข้อมูลจากแหล่งที่หาได้
 - ทำให้แน่ใจว่าสามารถใช้ข้อมูลนั้นได้
 - ตรวจสอบการเข้าถึง และความเข้ากันได้

กระบวนการวิทยาการข้อมูล

Table 2.1 Data Set		
Borrower ID	Credit Score	Interest Rate
01	500	7.31%
02	600	6.70%
03	700	5.95%
04	700	6.40%
05	800	5.40%
06	800	5.70%
07	750	5.90%
08	550	7.00%
09	650	6.50%
10	825	5.70%

กระบวนการวิทยาการข้อมูล

3. การเตรียมข้อมูล


- ตรวจสอบข้อผิดพลาด ข้อมูลที่ขาดหายไป และคุณภาพของข้อมูล
- ทำความสะอาดข้อมูล (Data Cleansing)
- รวบรวมข้อมูลจากหลายแหล่ง (Data Integration)
- แปลงข้อมูลให้อยู่ในรูปแบบที่ต้องการ (Data Transformation)

4. การสำรวจข้อมูล

- สร้างความเข้าใจที่ลึกซึ้งมากขึ้นในข้อมูล
- พยายามหาความสัมพันธ์และสอดคล้องกันของข้อมูล
- ใช้สถิติเชิงบรรยาย (Descriptive statistics)
- ทดลองในแบบจำลองข้อมูลพื้นฐาน

กระบวนการวิทยาการข้อมูล

Table 2.2 New Data with Unknown Interest Rate		
Borrower ID	Credit Score	Interest Rate
11	625	?




กระบวนการวิทยาการข้อมูล

5. การสร้างแบบจำลองข้อมูล

- สร้างแบบจำลองข้อมูล
- ใช้องค์ความรู้ที่เกี่ยวข้องทั้งหมด
สถิติ การเรียนรู้ของเครื่อง
หรืองานวิจัยที่เกี่ยวข้อง
- กระบวนการทำซ้ำเพื่อประเมินผลให้ดีขึ้น

6. การนำเสนอผลลัพธ์และวางขอบเขตการอัตโนมัติ

- นำผลลัพธ์ไปใช้งานในรูปแบบรายงาน ผลการวิเคราะห์
- นำไปแทรกในขอบเขตการอัตโนมัติ
- ระบบช่วยตัดสินใจ



1.5 การเรียนรู้ของเครื่อง (Machine Learning)



AI, Machine learning, Deep learning, Data science






Figure 1-1. AI, machine learning, deep learning, and data science (Tatsat et al., 2020)

AI, Machine learning, Deep learning, Data science






ที่มา: สรุปจาก Copeland, 2016

Artificial Intelligence (AI)


- Artificial Narrow Intelligence (ANI) หรือ ปัญญาประดิษฐ์แบบเบา (Weak AI) เช่น Siri, Amazon, AI Chat Bot
- Artificial General Intelligence (AGI) หรือ ปัญญาประดิษฐ์แบบเข้ม (Strong AI) หรือ Generative AI สร้างเนื้อหาขึ้นใหม่จากข้อมูลที่มีอยู่ เช่น Autonomous Car, Chat GPT
- Artificial Super Intelligence (ASI) หรือ ปัญญาประดิษฐ์แบบทรงปัญญา



Cross Industry Standard Process for Data Mining (CRISP-DM)



ผังการฝึกสอน การเรียนรู้ของเครื่อง



ชนิดของการเรียนรู้ของเครื่อง (Machine Learning)




Figure 1-2. Machine learning types (Tatsat et al., 2020)

การเรียนรู้แบบมีผู้ฝึกสอน (Supervised learning)




Figure 1-3. Regression versus classification (Tatsat et al., 2020)



Table 2.3 Training Data Set

Borrower	Credit Score (X)	Interest Rate (Y)
01	500	7.31%
02	600	6.70%
03	700	5.95%
05	800	5.40%
06	800	5.70%
08	550	7.00%
09	650	6.50%

รู้ X และ Y
ต้องการหา $f(X)$

Table 2.4 Test Data Set

Borrower	Credit Score (X)	Interest Rate (Y)
04	700	6.40%
07	750	5.90%
10	825	5.70%



Big Think

Type the two words:

reCAPTCHA™
stop spam.
read books.

การเรียนรู้แบบไม่มีผู้ฝึกสอน (Unsupervised learning)

- การลดมิติข้อมูล
- การแบ่งกลุ่ม
- การระบุรูปแบบความผิดปกติ
- การตรวจจับความสัมพันธ์




Figure 1-4. Dimensionality reduction (Tatsat et al., 2020)




Figure 1-5. Clustering (Tatsat et al., 2020)

การเรียนรู้แบบไม่มีผู้ฝึกสอน (Unsupervised learning)

Table 2.3 Training Data Set		
Borrower	Credit Score (X)	Interest Rate (Y)
01	500	ไม่รู้ Y
02	600	
03	700	
05	800	
06	800	
08	550	
09	650	

รู้ X

ต้องการหา Y หรือ $f(X)$

การเรียนรู้แบบเสริมกำลัง (Reinforcement learning)

- เรียนรู้จากประสบการณ์ ให้รางวัล/ลงโทษ
- คล้ายมีผู้ฝึกสอน แต่ไม่มีคำตอบชัด
- หาคำตอบจากการได้รางวัลที่ดีที่สุด
- พื้นฐาน trial-and-error




Figure 1-6. Reinforcement learning (Tatsat et al., 2020)



การประมวลภาษาธรรมชาติ (Natural Language Processing)


- ศึกษาองค์ประกอบต่างๆ ของภาษา เช่น ไวยากรณ์ การตัดคำ เพื่อให้เครื่องเข้าใจ โครงสร้างและความหมายของภาษาธรรมชาติ
- การรู้จำคำเฉพาะ
- การแยกส่วนประกอบของประโยค
- การถอดสาระสำคัญ
- จำแนกเจตนา
- วิเคราะห์อารมณ์และความรู้สึก

Google **ORG** is looking at buying **U.K. GPE** startup for **\$1 billion MONEY**

	Token	is_stop_word	lemma	POS
0	Google	False	Google	PROPN
1	is	True	be	VERB
2	looking	False	look	VERB
3	at	True	at	ADP
4	buying	False	buy	VERB
5	U.K.	False	U.K.	PROPN
6	startup	False	startup	NOUN
7	for	True	for	ADP
8	\$	False	\$	SYM
9	1	False	1	NUM
10	billion	False	billion	NUM


การวิเคราะห์เชิงลึก (Deep Learning)

- ใช้โครงข่ายประสาทเทียม (Neural Networks) ซ้อนกันหลายชั้น
- นำมาใช้ในการตรวจจับรูปแบบ (Pattern) หรือจัดหมวดหมู่ข้อมูล
- ประยุกต์ใช้กับงานได้หลากหลายทั้งปัญหา Classification และ Regression



การวิเคราะห์เชิงลึก (Deep Learning)

- ใช้ Convolutional Neural Network: CNN



สรุปหลักการ (Concepts)


รูปแบบการเรียนรู้

- การถดถอย (Regression) ทำนายเอาต์พุตที่เป็นข้อมูลเชิงปริมาณ
- การจำแนก (Classification) ทำนายเอาต์พุตที่เป็นข้อมูลเชิงคุณภาพ
- การหาความสัมพันธ์ (Association) ตรวจสอบความสัมพันธ์ระหว่างตัวแปร
- การแบ่งกลุ่ม (Clustering) จัดกลุ่มตัวอย่างที่มีความใกล้เคียงกันให้อยู่กลุ่มเดียวกัน

1.6 ธรรมนูญข้อมูล (Data Government)




โครงสร้างธรรมาภิบาลข้อมูล (Data Governance)



ที่มา : ธรรมาภิบาลข้อมูลภาครัฐ รูปที่ 9 หน้า 32


การจัดทำบัญชีข้อมูล (Data Catalog)

ระบบงานที่ทำหน้าที่บริหารจัดการบัญชีข้อมูลของหน่วยงานตามคำนิยาม



คลังเมทาดาทา (Metadata Repository) หรือพจนานุกรมข้อมูล (Data Dictionary)

- ข้อมูลที่ใช้อธิบายข้อมูลหลัก
- รวบรวมและจัดเก็บเมทาดาทา เพื่อสนับสนุนให้ผู้ที่ต้องการใช้ข้อมูลสามารถค้นหาและเข้าถึงได้โดยสะดวก



การประเมินคุณภาพของข้อมูล (Data Quality Assessment)

- เป็นเครื่องมือในการวัดความน่าเชื่อถือและประสิทธิภาพของการนำข้อมูลไปใช้
- มีการวางแผน การดำเนินการ และการควบคุมกิจกรรมต่างๆ รวมถึงการปรับปรุง เพื่อให้ข้อมูลมีคุณภาพ




1.7 เครื่องมือ






Python





- Rstudio
- ไลบรารีพื้นฐานที่นิยมใช้ได้แก่ Tidyverse, Tidymodels, Caret, Lubridate, Shiny และ ggplot2 เป็นต้น





WEKA

Weka Explorer

Preprocess Classify Cluster Associate Select attributes Visualize

Classifier

Choose **Logistic -R 1.0E-8 -M -1 -num-decimal-places 4**

Test options

☐ Use training set
☐ Supplied test set Set...
☒ Cross-validation Folds **10**
☐ Percentage split % **66**
More options...

(Nom) class

Start Stop

Result list (right-click for options)

07:02:55 - functions.Logistic

Classifier output

```
Correctly Classified Instances      312      88.8889 %
Incorrectly Classified Instances     39      11.1111 %
Kappa statistic                     0.753
Mean absolute error                  0.1283
Root mean squared error              0.3035
Relative absolute error              27.8593 %
Root relative squared error          63.26 %
Total Number of Instances           351

=== Detailed Accuracy By Class ===
```


	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC
	0.794	0.058	0.885	0.794	0.837	0.756
	0.942	0.206	0.891	0.942	0.916	0.756
Weighted Avg.	0.889	0.153	0.889	0.889	0.887	0.756

```
=== Confusion Matrix ===
 a  b  <-- classified as
100 26 | a = b
 13 212 | b = g
```

Status


OK Log x 0

Unified Data Science Platform






KNIME



Gartner Magic Quadrant for Data Science and Machine Learning Platforms



เครื่องมือ Data Integration



เครื่องมือ Data Integration

ตัวอย่างเครื่องมือ ETL

- Xplenty: cloud-based ETL
- Talend: open-source ETL
- Stitch: open-source ETL
- Pentaho Data Integration
- Informatica PowerCenter: enterprise data integration platform
- Oracle Data Integrator (ODI): comprehensive data integration solution
- Skyvia: cloud platform for big data integration, migration, and backup
- Fivetran: cloud-based ETL




Gartner Magic Quadrant for Data Integration Tools




เครื่องมือ Business Intelligence

Tableau




เครื่องมือ Business Intelligence

Microsoft Power BI




เครื่องมือ Business Intelligence

Looker Studio (Google Data Studio)



Magic Quadrant for Analytics and Business Intelligence Platforms




1.8 กรณีสึกษา




การวิเคราะห์ข้อมูลด้านสุขภาพ

Data Science in Healthcare




- การทดสอบที่เหมาะสม
- การแนะนำการรักษาที่แม่นยำ

การวิเคราะห์ข้อมูลสภาพภูมิอากาศ





การวิเคราะห์ข้อมูลอุตุนิยมวิทยา

University of Warwick, UK ใช้ข้อมูลจากสื่อเช่น ภาพที่เกี่ยวข้องกับน้ำท่วม เฮอริเคน ร่วมกับสถานีตรวจวัดอากาศ จำกั้ดวงการทำนายสภาพอากาศ




การวิเคราะห์ข้อมูลความสัมพันธ์

ระบบแนะนำ



การวิเคราะห์ข้อมูลความสัมพันธ์

ระบบแนะนำลูกค้า 425 degree



การวิเคราะห์การแบ่งกลุ่ม (Clustering)


แบ่งกลุ่มลูกค้า 425 degree



<https://www.425degree.com/>

การวิเคราะห์ภาษาธรรมชาติ

การแยกเซตลูกค้า 425 degree



การรู้จำเสียงอัตโนมัติด้วยการวิเคราะห์ภาษาธรรมชาติ

Automatic Speech Recognition: ASR

Results on `test-unique` split of Thai Common Voice 7.0


Word Error Rate (WER) and Character Error Rate (CER); the lower the better

	WER PyThaiNLP 2.3.1	WER deepcut	CER
Kaldi from scratch	23.040		7.570
Ours without spell correction	13.634	8.152	2.813
Ours with spell correction	17.996	14.168	5.226
Google Web Speech API※	13.711	10.860	7.357
Microsoft Bing Speech API※	12.579	9.621	5.017
Amazon Transcribe※	21.863	14.488	7.078
NECTEC AI for Thai Partii API※	20.106	15.516	9.551

※ APIs are not fine-tuned with Common Voice 7.0 data


[Get the data](#) • Created with [Datawrapper](#) <https://huggingface.co/airesearch/wav2vec2-large-xlsr-53-th>

การจำแนกรูปภาพด้วยการวิเคราะห์เชิงลึก




Source: <https://towardsdatascience.com/the-most-intuitive-and-easiest-guide-for-convolutional-neural-network-3607be47480>

ตรวจจับและการจำแนกรูปภาพ



ตรวจจับและการจำแนกความหมายวิดีโอ



Otani M., Nakashima Y., Rahtu E., Heikkilä J., Yokoya N. (2017) Video Summarization Using Deep Semantic Features. In: Lai SH., Lepetit V., Nishino K., Sato Y. (eds) Computer Vision – ACCV 2016. ACCV 2016. Lecture Notes in Computer Science, vol 10115. Springer, Cham. https://doi.org/10.1007/978-3-319-54193-8_23.


รถยนต์ไร้คนขับ

ต้องใช้เทคโนโลยีหลายชนิดเพื่อเป็นข้อมูลสำหรับการตัดสินใจในการขับอัตโนมัติ

Object segmentation




Lane detection




Source: <https://www.xpertup.com/downloads/advanced-lane-detection/>


Visual Inspection



Smart farming



การวิเคราะห์ข้อมูลอนุกรมเวลา (Time Series Analytics)



<https://doi.org/10.7287/peerj.preprints.3190v2>

Generative AI รอบตัวเรา



News article
generation



Knowledge
base




Quiz
generation



Image
generation



Voice
transcription




Personalized
news




Article
summarization



Fact
checking



Comment
moderation



Conversational
agent

Q & A

Ref

- Data Science from Scratch First Principles with Python, 2ed, Joel Grus
- Tatsat, H., Puri, S., Lookabaugh, B. Machine Learning & Data Science Blueprints for Finance. (2020). O'Reilly Media, Inc.
- Python Data Science Handbook, 2ed, Jake VanderPlas
- Getting Started with Data Science, Murtaza Haider, IBM Press
- Kotu, V., Deshpande, B. Predictive Analytics and Data Mining Concepts and Practice with RapidMiner. (2015). Elsevier.
- Introduction to Data Science, Laura Igual and Santi Seguí, Springer

