



ดำรงฤทธิ์ เศรษฐศิริโชค

2. กระบวนการวิทยาการข้อมูล

2.1 กรอบงาน CRISP-DM

2.2 การทำความเข้าใจธุรกิจและตั้งเป้าหมาย

2.3 การทำความเข้าใจข้อมูล

2.4 การสำรวจและเตรียมข้อมูล


2.5 การสร้างแบบจำลองข้อมูล

2.6 การประเมินประสิทธิภาพแบบจำลอง

2.7 การปรับใช้และผลตอบรับ





2.1 กรอบงาน CRISP-DM



กรอบงานสำหรับ Machine Learning

- การทำความเข้าใจธุรกิจและตั้งเป้าหมาย
- การทำความเข้าใจข้อมูล
- การสำรวจและเตรียมข้อมูล
- การสร้างแบบจำลองข้อมูล
- การประเมินประสิทธิภาพแบบจำลอง
- การปรับใช้และผลตอบรับ


กระบวนการงานวิทยาการข้อมูล



2.2 การทำความเข้าใจธุรกิจและตั้งเป้าหมาย



ออกแบบเป้าหมายวิจัย



ออกแบบเป้าหมายวิจัย

- ตั้งคำถาม – What, Why, How
- ค้นหาว่า “อะไรคือปัญหา” ให้ชัดเจน
- เข้าใจบริบทของปัญหา
- วางวัตถุประสงค์เพื่อรองรับเป้าหมาย

“ทำอย่างไรจึงลดค่าใช้จ่ายในการทำกิจการของบริษัท”

เป้าหมายคือปรับปรุงประสิทธิภาพ หรือ เป้าหมายคือเพิ่มกำไร

ร่างเอกสารโครงการ


- เป็นทางการหรือไม่ก็ได้
- ระบุเป้าหมายที่ชัดเจน
- ตั้งทีมงาน กำหนดหน้าที่
- แนวทางดำเนินการเพื่อบรรลุวัตถุประสงค์
- ทรัพยากรทั้งหมดที่ต้องใช้
- แนวทาง Proof of Concept: POC
- กำหนดตัววัดความสำเร็จ
- วางตารางงานและกรอบเวลา


ตัวอย่างกรณีศึกษา #1

- คำถามจากผู้ให้บริการธุรกิจประกันภัยด้านสุขภาพ

➤ “จำกัดกรอบวงเงิน ในขณะที่คุณภาพการให้บริการดีที่สุด”


- เป้าหมาย – เพิ่มคุณภาพการให้บริการ แต่ไม่เพิ่มต้นทุน
- วัตถุประสงค์ – ทบทวนกระบวนการเพื่อหาจุดบอด หรือกระบวนการทำงานที่ขาดประสิทธิภาพ






ตัวอย่างกรณีศึกษา #1 – ทำความเข้าใจบริบทของปัญหา

- ศึกษาบริบทของปัญหาพบว่ามียัตราการเข้ารักษาซ้ำ
- ส่วนใหญ่เป็นผู้ใช้โรคหัวใจ






ตัวอย่างกรณีศึกษา #1 – ระบุความต้องการเชิงธุรกิจ


1. ทำนายการกลับเข้ารับรักษาของผู้ป่วยแต่ละราย (Congestive Heart Failure: CHF)
2. ทำนายอัตราความเสี่ยงที่จะกลับเข้ารับรักษาของผู้ป่วยแต่ละราย
3. ค้นหากลุ่มของปัจจัยที่ส่งผลต่อการทำนาย
4. สร้างกระบวนการที่เข้าใจง่าย เพื่อประยุกต์ใช้ในกลุ่มผู้ป่วยใหม่ โดยเน้นที่ปัจจัยที่ส่งผลต่อความเสี่ยง

เลือกการวิเคราะห์ที่เหมาะสม



วิเคราะห์ความสัมพันธ์ ➡ ความน่าจะเป็น ➡ หาจุดที่ดีที่สุด


ตัวอย่างการทำนายด้วยการจำแนก



2.3 การทำความเข้าใจข้อมูล




ทำความเข้าใจข้อมูล





ดึงข้อมูลเพื่อทำความเข้าใจ

- เริ่มจากข้อมูลภายใน ข้อมูลที่สัมพันธ์กับเป้าหมาย
- เลือกข้อมูลหลักและคุณภาพดีก่อน



ข้อมูล

- ชุดข้อมูล (data set)
- ลักษณะประจำ (attributes)

Student ID	Year	Grade Point Average (GPA)	...
	⋮		
1034262	Senior	3.24	...
1052663	Sophomore	3.51	...
1082246	Freshman	3.62	...
	⋮		

ลักษณะประจำ (Attribute)

- ลักษณะเฉพาะเพื่ออธิบายถึงสิ่งต่างๆ

Attribute Type		Description	Examples	Operations
Categorical (Qualitative)	Nominal	The values of a nominal attribute are just different names; i.e., nominal values provide only enough information to distinguish one object from another. (=, ≠)	zip codes, employee ID numbers, eye color, gender	mode, entropy, contingency correlation, χ^2 test
	Ordinal	The values of an ordinal attribute provide enough information to order objects. (<, >)	hardness of minerals, { <i>good</i> , <i>better</i> , <i>best</i> }, grades, street numbers	median, percentiles, rank correlation, run tests, sign tests
Numeric (Quantitative)	Interval	For interval attributes, the differences between values are meaningful, i.e., a unit of measurement exists. (+, -)	calendar dates, temperature in Celsius or Fahrenheit	mean, standard deviation, Pearson's correlation, <i>t</i> and <i>F</i> tests
	Ratio	For ratio variables, both differences and ratios are meaningful. (×, /)	temperature in Kelvin, monetary quantities, counts, age, mass, length, electrical current	geometric mean, harmonic mean, percent variation

ชนิดของชุดข้อมูล

<i>Tid</i>	Refund	Marital Status	Taxable Income	Defaulted Borrower
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

(a) Record data.

<i>TID</i>	<i>ITEMS</i>
1	Bread, Soda, Milk
2	Beer, Bread
3	Beer, Soda, Diapers, Milk
4	Beer, Bread, Diapers, Milk
5	Soda, Diapers, Milk

(b) Transaction data.

Projection of x Load	Projection of y Load	Distance	Load	Thickness
10.23	5.27	15.22	27	1.2
12.65	6.25	16.22	22	1.1
13.54	7.23	17.34	23	1.2
14.27	8.43	18.45	25	0.9

	team	coach	play	ball	score	game	win	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0

Time	Customer	Items Purchased
t1	C1	A, B
t2	C3	A, C
t2	C1	C, D
t3	C2	A, D
t4	C2	E
t5	C1	A, E

Customer	Time and Items Purchased
C1	(t1: A,B) (t2:C,D) (t5:A,E)
C2	(t3: A, D) (t4: E)
C3	(t2: A, C)


(a) Sequential transaction data.

```


GGTTCCGCCTTCAGCCCCGCGCC
CGCAGGGCCCCGCCCCGCGCCGTC
GAGAAGGGCCCGCCTGGCGGGCG
GGGGGAGGCGGGGCGCCCGAGC
CCAACCGAGTCCGACCAGGTGCC
CCCTCTGCTCGGCCTAGACCTGA
GCTCATTAGGCGGCAGCGGACAG
GCCAAGTAGAACACGCGAAGCGC
TGGGCTGCCTGCTGCGACCAGGG

```

(b) Genomic sequence data.



(c) Temperature time series.




(d) Spatial temperature data.


ดึงข้อมูลเพื่อทำความเข้าใจ

- ข้อมูลหน่วยงานภายนอก
- เช่นต้องการวิเคราะห์ด้านประกันสุขภาพ
 - ข้อมูลสาธารณสุข ข้อมูลสังคมออนไลน์
- ข้อมูลเปิดภาครัฐ <https://data.go.th/>
- หาความสัมพันธ์ข้อมูลและตรวจสอบคุณภาพข้อมูลเบื้องต้น
 - แก้ไขค่า
 - ตรวจสอบสถิติเชิงบรรยายพื้นฐาน univariate/pairwise statistics, Histogram
 - distributions, correlations, outliers
- นำไปสู่การเตรียมข้อมูลได้อย่างมีประสิทธิภาพ

Open data site	Description
Data.gov	The home of the US Government's open data
https://open-data.europa.eu/	The home of the European Commission's open data
Freebase.org	An open database that retrieves its information from sites like Wikipedia, MusicBrains, and the SEC archive
Data.worldbank.org	Open data initiative from the World Bank
Aiddata.org	Open data for international development
Open.fda.gov	Open data from the US Food and Drug Administration

ตัวอย่าง Histogram






ตัวอย่างกรณีศึกษา #1 – การดึงข้อมูลเพื่อทำความเข้าใจ

- ตีกรอบกลุ่มตัวอย่างที่ต้องการ
 - ผู้ป่วยที่มีประกันสุขภาพ
 - เข้ารับการตรวจเรื่องโรคหัวใจในช่วง 1 ปีที่ผ่านมา
 - มีการติดตามเกี่ยวกับโรคหัวใจในรอบ 6 เดือน
 - เลือกตัวแปรและผลลัพธ์ที่จะเป็น outcome





ตัวอย่างกรณีศึกษา #1 – แหล่งข้อมูล


- ค้นหาแหล่งข้อมูล
 - ข้อมูลสมาชิกภายใน
 - ข้อมูลผู้ป่วยของโรงพยาบาล
 - ข้อมูลจากระบบสินไหมทดแทน
 - ข้อมูลจากระบบคลังข้อมูลที่เกี่ยวข้อง
- จะพบว่า บางแหล่งข้อมูลที่ต้องการไม่สามารถเข้าถึงได้
 - ไม่มีสิทธิ์ในการเข้าถึง เช่น ข้อมูลการรักษา การจ่ายยา
 - ฐานข้อมูลไม่เชื่อมต่อกัน



2.4 การสำรวจและเตรียมข้อมูล



การเตรียมข้อมูล




ประโยชน์ของการเตรียมข้อมูล

- ข้อมูลที่ได้มาอาจยังไม่สามารถนำไปใช้ได้ทันที
- จำเป็นต้องสกัดและทำความสะอาดข้อมูลก่อนนำไปใช้สร้างรายงานหรือแบบจำลองข้อมูล
- ข้อมูลยังมีคุณภาพ รายงานและแบบจำลองยังมีคุณภาพ
- จัดรูปแบบให้อยู่ในรูปที่เหมาะสม
- ได้ตรวจสอบข้อผิดพลาดของข้อมูล

2.4 การสำรวจและเตรียมข้อมูล

การทำความสะอาดข้อมูล



การทำความสะอาดข้อมูล

- เน้นการลดข้อมูลที่เข้าเกณฑ์ผิดพลาด
- พิจารณาความสอดคล้องกันของข้อมูลเป็นหลัก
 - ข้อผิดพลาดจากการแปลความหมาย (Interpretation error) เช่น กลุ่มตัวอย่างข้อมูลบุคคล อายุมากกว่า 200 ปี เป็นต้น
 - ข้อผิดพลาดจากความสอดคล้องกันกับบริบทที่พิจารณา เช่น ข้อมูลมีค่าต่างไปจากมาตรฐานที่ควรเป็น
- ลดข้อมูลซ้ำซ้อน

012	232	33.5	0	10.7
020	121	16.9	2	210.1
027	165	24.0	0	427.6
⋮				

Table 2.2 An overview of common errors

General solution	
Try to fix the problem early in the data acquisition chain or else fix it in the program.	
Error description	Possible solution
<i>Errors pointing to false values within one data set</i>	
Mistakes during data entry	Manual overrules
Redundant white space	Use string functions
Impossible values	Manual overrules
Missing values	Remove observation or value
Outliers	Validate and, if erroneous, treat as missing value (remove or insert)
<i>Errors pointing to inconsistencies between data sets</i>	
Deviations from a code book	Match on keys or else use manual overrules
Different units of measurement	Recalculate
Different levels of aggregation	Bring to same level of measurement by aggregation or extrapolation

หาข้อผิดพลาดของข้อมูลด้วยแผนภาพ






Figure 2.5 The encircled point influences the model heavily and is worth investigating because it can point to a region where you don't have enough data or might indicate an error in the data, but it also can be a valid data point.

ข้อมูลผิดพลาด

- เกิดจากมนุษย์
- เกิดจากเครื่องจักรหรือฮาร์ดแวร์
- เกิดภายในกระบวนการ ETL
- ช่องว่างเกิน – “FR ” – “FR”
- ตัวอักษรพิมพ์ใหญ่ – เล็ก
- ค่าที่เป็นไปไม่ได้
- Outlier

Table 2.3 Detecting outliers on simple variables with a frequency table

Value	Count
Good	1598647
Bad	1354468
Godo	15
Bade	1



Missing Value

- บางข้อมูลที่ขาดหายไป
- ไม่จำเป็นว่าข้อมูล record นั้นจะผิดพลาดเสมอไป


Table 2.4 An overview of techniques to handle missing data

Technique	Advantage	Disadvantage
Omit the values	Easy to perform	You lose the information from an observation
Set value to null	Easy to perform	Not every modeling technique and/or implementation can handle null values
Impute a static value such as 0 or the mean	Easy to perform You don't lose information from the other variables in the observation	Can lead to false estimations from a model
Impute a value from an estimated or theoretical distribution	Does not disturb the model as much	Harder to execute You make data assumptions
Modeling the value (nondependent)	Does not disturb the model too much	Can lead to too much confidence in the model Can artificially raise dependence among the variables Harder to execute You make data assumptions


ข้อมูลผิดพลาด

- ข้อมูลมีการแทนค่า อาจทำให้เข้าใจผิด
เช่น “0” = “negative”
“5” = “very positive”
- หน่วยของการวัด
- ระดับการรวมกลุ่ม (Levels of aggregation) เช่น ข้อมูลรายวัน รายเดือน รายปี

สัญญาณรบกวน




(a) Time series.



(b) Time series with noise.

สัญญาณรบกวน




(a) Three groups of points.

(b) With noise points (+) added.

2.4 การสำรวจและเตรียมข้อมูล

การรวมข้อมูล



การรวมข้อมูล – Join





Figure 2.7 Joining two tables on the Item and Region keys

การรวมข้อมูล – Union




Figure 2.8 Appending data from tables is a common operation but requires an equal structure in the tables being appended.

การรวมข้อมูล – Union




Figure 2.9 A view helps you combine data without replication.

การทำข้อมูลให้สมบูรณ์ (Data Enrichment)


- ทำข้อมูลให้สมบูรณ์ขึ้น

Product class	Product	Sales in \$	Sales t-1 in \$	Growth	Sales by product class	Rank sales
A	B	X	Y	$(X-Y) / Y$	AX	NX
Sport	Sport 1	95	98	-3.06%	215	2
Sport	Sport 2	120	132	-9.09%	215	1
Shoes	Shoes 1	10	6	66.67%	10	3

Figure 2.10 Growth, sales by product class, and rank sales are examples of derived and aggregate measures.

2.4 การสำรวจและเตรียมข้อมูล

การแปลงข้อมูล



การแปลงข้อมูล

- แปลงรูปร่างข้อมูล เช่นปรับให้อยู่ในรูปตาราง (Variable transformation)
- ปรับให้อยู่ในรูปแบบที่พร้อมสำหรับทำแบบจำลอง
- ลดขนาดข้อมูลที่ไม่จำเป็น
- เพิ่มหรือลดตัวแปร (Feature Engineering)
- บางครั้ง การแปลงข้อมูลให้เป็นเชิงเส้น จะทำให้การสร้างแบบจำลองง่ายขึ้น
- การแปลงข้อมูลอื่นๆ
 - Aggregation
 - Sampling
 - Feature subset selection
 - Feature creation
 - Discretization and binarization

ตัวอย่างการแปลงข้อมูล

- ความสัมพันธ์ที่ไม่เป็นเชิงเส้นระหว่าง x และ y เช่น $y = ae^{bx}$
- การใช้ $\log$ จะทำให้สามารถแก้ปัญหาค่าประมาณค่าได้ง่ายขึ้น
- ในบางกรณี หากมีจำนวนตัวแปรมากขึ้น อาจมีการรวมตัวแปรเข้าด้วยกัน
- Normalization การทำให้ข้อมูลเป็นค่ามาตรฐาน เช่น MinMaxScaler

$$x = (x - \min(x)) / (\max(x) - \min(x))$$

- Standardization ปรับค่าเฉลี่ยให้อยู่ที่ 0 ทำให้ค่าไม่ใหญ่เกินไป

$$x' = \frac{(x - \bar{x})}{S_x}$$

Scale

$$x = \log(x)$$

x	1	2	3	4	5	6	7	8	9	10
log(x)	0.00	0.43	0.68	0.86	1.00	1.11	1.21	1.29	1.37	1.43
y	0.00	0.44	0.69	0.87	1.02	1.11	1.24	1.32	1.38	1.46





Figure 2.11 Transforming x to $\log x$ makes the relationship between x and y linear (right), compared with the non-log x (left).

การลดจำนวนตัวแปร

- จำนวนตัวแปรเยอะ ไม่ได้ทำให้แบบจำลองดีขึ้นเสมอไป
- ตัวแปรนั้นไม่มีความรู้ใหม่ที่แบบจำลองต้องการ (Redundant Feature)
- อาจถูกมองเป็นสัญญาณรบกวน (Noise)
- ตัวแปรที่ไม่เกี่ยวข้องหรือไม่สัมพันธ์กับแบบจำลอง (Irrelevant Feature)

การเลือกเซตตัวแปร (Feature Subset Selection)



การจำลองตัวแปร (Dummy)

Customer	Year	Gender	Sales
1	2015	F	10
2	2015	M	8
1	2016	F	11
3	2016	M	12
4	2017	F	14
3	2017	M	13

M F

Customer	Year	Sales	Male	Female
1	2015	10	0	1
1	2016	11	0	1
2	2015	8	1	0
3	2016	12	1	0
3	2017	13	1	0
4	2017	14	0	1

Figure 2.13 Turning variables into dummies is a data transformation that breaks a variable that has multiple classes into multiple variables, each having only two possible values: 0 or 1.

การจำลองตัวแปร

- Binarization
- จากข้อมูล Categorical เป็น Binary

Table 2.5. Conversion of a categorical attribute to three binary attributes.

Categorical Value	Integer Value	x_1	x_2	x_3
<i>awful</i>	0	0	0	0
<i>poor</i>	1	0	0	1
<i>OK</i>	2	0	1	0
<i>good</i>	3	0	1	1
<i>great</i>	4	1	0	0

Table 2.6. Conversion of a categorical attribute to five asymmetric binary attributes.

Categorical Value	Integer Value	x_1	x_2	x_3	x_4	x_5
<i>awful</i>	0	1	0	0	0	0
<i>poor</i>	1	0	1	0	0	0
<i>OK</i>	2	0	0	1	0	0
<i>good</i>	3	0	0	0	1	0
<i>great</i>	4	0	0	0	0	1

Ordinal Encoding

OneHot Encoding


การรวม (Aggregate)

- ข้อมูลที่สามารถรวมกลุ่มกันได้ – เฉลี่ยรายเดือน / รายพื้นที่
- บางครั้งทำให้เสียรายละเอียดของข้อมูล


Table 2.4. Data set containing information about customer purchases.

Transaction ID	Item	Store Location	Date	Price	...
⋮	⋮	⋮	⋮	⋮	
101123	Watch	Chicago	09/06/04	\$25.99	...
101123	Battery	Chicago	09/06/04	\$5.99	...
101124	Shoes	Minneapolis	09/06/04	\$75.00	...
⋮	⋮	⋮	⋮	⋮	

ตัวอย่างการรวมเชิงความถี่



(a) Histogram of standard deviation of average monthly precipitation



(b) Histogram of standard deviation of average yearly precipitation

Figure 2.8. Histograms of standard deviation for monthly and yearly precipitation in Australia for the period 1982–1993.

การสุ่ม (Sampling)

- แบบสุ่มอย่างง่าย – ประชากรมีลักษณะใกล้เคียงกัน
 - Sampling without replacement
 - Sampling with replacement
- การสุ่มตัวอย่างแบบชั้นภูมิ (Stratified Sampling)
 - แบ่งกลุ่มประชากรตามเงื่อนไขที่กำหนดก่อน จากนั้นสุ่มประชากรแต่ละกลุ่มตามสัดส่วน



(a) 8000 points



(b) 2000 points




(c) 500 points

Figure 2.9. Example of the loss of structure with sampling.


การสร้างตัวแปร

- คัดแยกคุณลักษณะเด่น (Feature Extraction)
- ดึงความสำคัญข้อมูล
- อาจเป็นรูปแบบความถี่
- ข้อมูลขนาดเล็กลง
- ปรับมุมมองข้อมูล




Discretization


จากข้อมูลต่อเนื่อง $\rightarrow$ ลำดับชั้น




(a) Original data.



(b) Equal width discretization.




(c) Equal frequency discretization.



(d) K-means discretization.




2.4 การสำรวจและเตรียมข้อมูล

การสำรวจข้อมูล




วิซวลไลเซชันด้วยแผนภาพ

- แผนภาพ เช่น ฮิสโตแกรม
- Interactive – <http://bost.ocks.org/mike/sankey/>



Scatter plots






Figure 2.16 Drawing multiple plots together can help you understand the structure of your data over multiple variables.





Figure 2.17. Scatter plots illustrating correlations from -1 to 1 .

Pareto diagram

- 80/20 rule
- cumulative = % ឥរិយាបថ



<https://www.cec.health.nsw.gov.au/>






Figure 2.18 Link and brush allows you to select observations in one plot and highlight the same observations in the other plots.

Box Plots







ตัวอย่างกรณีศึกษา #1 – การเตรียมข้อมูล

- สร้างเงื่อนไขหรือกรอบในการกรองข้อมูล
- กรอบเวลาในการเลือกข้อมูล

ข้อมูลที่บ้านทีก

- การक्रम: ผู้ให้บริการ สิ่งอำนวยความสะดวก ยา
- ผู้ป่วยใน/ ผู้ป่วยนอก: ประวัติการรักษา การวินิจฉัยของแพทย์ เป็นต้น
- ข้อมูลมากหรือน้อยขึ้นอยู่กับประวัติ
- ข้อมูลต่อผู้ป่วย 1 คนอาจมีหลายการบันทึก






ตัวอย่างกรณีศึกษา #1 – การรวมข้อมูล

การรวมข้อมูลในระดับผู้ป่วย

- ข้อมูล 1 แถวต่อผู้ป่วย 1 คน
- สร้างตัวแปรที่สอดคล้องกับการดำเนินการ
 - ผู้ป่วยนอกเดินที่ทางมารับบริการครั้งแรก
 - ผู้ป่วยใน: ความถี่ รับบริการล่าสุด ผลวินิจฉัย จำนวนวันที่นอนโรงพยาบาล ขั้นตอน การสั่งยา
- ข้อมูลการป่วยโรคหัวใจ (Congestive Heart Failure: CHF)



ตัวอย่างกรณีศึกษา #1 – การทำข้อมูลให้สมบูรณ์

- ย้อนมาพิจารณาข้อมูลที่มีว่ามีความสำคัญเพียงพอแล้วหรือยัง
- ทำการศึกษาเพิ่มเติม
- รวมข้อมูลเข้าด้วยกัน
- มีรายการตัวแปรครบถ้วน
- กำหนดป้ายกำกับ (Label) → กลับเข้ารับรักษา CHF ใน 30 วัน หลังจากออกจากโรงพยาบาล (Yes/No)
- แบ่งข้อมูลสำหรับฝึกสอนและทดสอบ เช่นผู้ป่วยเป้าหมาย 2,343 คน
 - แบ่ง 70% / 30%
 - ชุดข้อมูลฝึกสอน 1,640 คน
 - ชุดข้อมูลทดสอบ 703 คน

2.5 การสร้างแบบจำลองข้อมูล



ตัวอย่างแบบจำลองข้อมูลการถดถอยเชิงเส้น (Linear Regression)




Figure 2.22 Linear regression tries to fit a line while minimizing the distance to each point

Python StatsModels

Listing 2.1 Executing a linear prediction model on semi-random data

```
import statsmodels.api as sm
import numpy as np
predictors = np.random.random(1000).reshape(500,2)
target = predictors.dot(np.array([0.4, 0.6])) + np.random.random(500)
lmRegModel = sm.OLS(target,predictors)
result = lmRegModel.fit()
result.summary()
```

**Imports required
Python modules.**

**Fits linear
regression
on data.**

**Shows model
fit statistics.**

**Creates random data for
predictors (x-values) and
semi-random data for
the target (y-values) of the
model. We use predictors as
input to create the target so
we infer a correlation here.**

**** ทดลองกับ Python Virtual Environment**

results.summary()

Dep. Variable:	y	R-squared:	0.893
Model:	OLS	Adj. R-squared:	0.893
Method:	Least Squares	F-statistic:	2088.
Date:	Fri, 30 Oct 2015	Prob (F-statistic):	7.13e-243
Time:	12:44:31	Log-Likelihood:	-176.74
No. Observations:	500	AIC:	357.5
Df Residuals:	498	BIC:	365.9
Df Model:	2		
Covariance Type:	nonrobust		

Model fit: higher is better but too high is suspicious.

Adjusted R-squared และ R-squared ต่างกันที่ Penalty

p-value to show whether a predictor variable has a significant influence on the target. Lower is better and <0.05 is often considered “significant.”

	coef	std err	t	P> t	[95.0% Conf. Int.]
x1	0.7658	0.040	19.130	0.000	0.687 0.844
x2	1.1252	0.039	28.603	0.000	1.048 1.202

Omnibus:	34.269	Durbin-Watson:	1.943
Prob(Omnibus):	0.000	Jarque-Bera (JB):	13.480
Skew:	-0.125	Prob(JB):	0.00118
Kurtosis:	2.235	Cond. No.	2.51

Linear equation coefficients.
 $y = 0.7658x_1 + 1.1252x_2$.

Figure 2.23 Linear regression model information output

ตัวอย่างแบบจำลอง K-nearest neighbor




Figure 2.24 K-nearest neighbor techniques look at the k-nearest point to make a prediction.

Python Scikit-learn

Listing 2.2 Executing k-nearest neighbor classification on semi-random data

```
from sklearn import neighbors
predictors = np.random.random(1000).reshape(500, 2)
target = np.around(predictors.dot(np.array([0.4, 0.6])) +
                    np.random.random(500))
clf = neighbors.KNeighborsClassifier(n_neighbors=10)
knn = clf.fit(predictors, target)
knn.score(predictors, target)
```

Imports modules.

Creates random predictor data and semi-random target data based on predictor data.

Fits 10-nearest neighbors model.

Gets model fit score: what percent of the classification was correct?

Confusion Matrix

		Actual Condition	
		Total Samples	
Output of Classifier	Classify Positive	Actual Positive	Actual Negative
	Classify Negative	TP	FP
		FN	TN

```
prediction = knn.predict(predictors)
metrics.confusion_matrix(target,prediction)
```

```
In [45]: metrics.confusion_matrix(target,prediction)
```




Figure 2.25 Confusion matrix: it shows how many cases were correctly classified and incorrectly classified by comparing the prediction with the real values. Remark: the classes (0,1,2) were added in the figure for clarification.



<https://neeraj-kumar-vaid.medium.com/>

2.6 การประเมินประสิทธิภาพแบบจำลอง



การประเมินประสิทธิภาพ แบบจำลอง

- เก็บบางส่วนของข้อมูลไว้ประเมิน
- ตัวอย่างวิธี “holdout”
- ตัวอย่างใช้ค่าคลาดเคลื่อน Mean Square Error: MSE นิยมใช้สำหรับ
แบบจำลองการถดถอยเชิงเส้น

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (Predicted_i - Actual_i)^2}{N}}$$

size = 3 * price

	n	Size	Price	Predicted model 1	Predicted model 2	Error model 1	Error model 2
80% train	1	10	3	size = 10			
	2	15	5				
	3	18	6				
	4	14	5				
	...	...					
	800	9	3				
	801	12	4	12	10	0	2
	802	13	4	12	10	1	3
	...						
	999	21	7	21	10	0	11
20% test	1000	10	4	12	10	-2	0
Total						5861	110225

Figure 2.27 A holdout sample helps you compare models and ensures that you can generalize results to data that the model has not yet seen.


การประเมินประสิทธิภาพแบบจำลอง

- สำหรับแบบจำลองการจำแนก
- Accuracy ความแม่นยำ = $(TP + TN) / N$
- Classification Error = $1 - \text{Accuracy}$
- Precision = $TP / (TP + FP)$
- Recall = $TP / (TP + FN)$
- F-score (F_1 score)

		Actual Condition	
		Total Samples	
Output of Classifier	Classify Positive	Actual Positive	Actual Negative
	Classify Negative	TP	FP
		FN	TN

เส้นโค้ง ROC


- แบบจำลองสามารถแยกแยะสองสิ่งได้ดีเพียงใด
- เหมาะสำหรับการประเมินประสิทธิภาพของข้อมูลไม่สมดุล
- พิจารณาทั้ง True Positive Rate หรือ TPR และ True Negative Rate หรือ TNR




2.7 การปรับใช้และผลตอบรับ




Deployment Concept




Deployment Concept



Deployment Concept




Model monitoring example



MLOps Levels 0

MLOps level 0: Manual process

Less frequent releases, so no CI/CD



แบบฝึกหัดท้ายบท

- กลุ่ม 3 คน ปรัชชาหาโจทย์
- หาแหล่งข้อมูล <https://www.kaggle.com/datasets> หรืออื่นๆ
- ทำความเข้าใจธุรกิจและตั้งเป้าหมาย – ศึกษาเพื่อกำหนดเป้าหมายวิจัย
- หาตัวอย่างกรณีศึกษาเพื่อนำเสนอกระบวนการวิทยาการข้อมูล

Q & A