






ดำรงฤทธิ์ เศรษฐศิริโชค

ตัวอย่างปัญหา OBJECT CHARACTER RECOGNITION (OCR)











010010010010010




IS LEARNING FEASIBLE?



$f = -1$



$f = +1$



$f = ?$

MACHINE LEARNING : $Y = F(X)$

- รู้ x และ y ต้องการหา f เป็นปัญหา supervised learning
- รู้ x ต้องการหา y หรือ $f(x)$ เป็นปัญหา unsupervised learning
- รู้ y และ f ต้องการหา x เป็นปัญหา optimization


OUTSIDE THE DATA SET

x_1	x_2	x_3	y
0	0	0	0
0	0	1	1
0	1	0	1
0	1	1	0
1	0	0	1


OUTSIDE THE DATA SET

x_1	x_2	x_3	y	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8
0	0	0	0	0	0	0	0	0	0	0	0
0	0	1	1	1	1	1	1	1	1	1	1
0	1	0	1	1	1	1	1	1	1	1	1
0	1	1	0	0	0	0	0	0	0	0	0
1	0	0	1	1	1	1	1	1	1	1	1
1	0	1	?	0	0	0	0	1	1	1	1
1	1	0	?	0	0	1	1	0	0	1	1
1	1	1	?	0	1	0	1	0	1	0	1


LEARNING ALGORITHMS




WHICH MODEL IS BETTER?




WHICH MODEL IS BETTER?



TRAINING VERSUS TESTING



TOP-DOWN VS. BOTTOM-UP APPROACHES TO DATA SCIENCE




Q&A



WHAT IS DEEP LEARNING ?

คุณเคยเห็นรูปภาพลักษณะนี้หรือไม่ ?



Application นี้คือข้อใด?

- Artificial intelligence
- Machine learning
- Deep learning

ARTIFICIAL INTELLIGENCE

Early artificial intelligence
stirs excitement

ปัญญาประดิษฐ์

ระบบที่สามารถ
เรียนรู้ใช้เหตุผล
ปฏิบัติ และปรับตัวได้

MACHINE LEARNING

Machine learning
begins to flourish

การเรียนรู้ของเครื่อง อัลกอริทึม

ที่มีความสามารถพัฒนา
ตัวเอง จากประสบการณ์
ที่ได้จากการสังเคราะห์
ข้อมูลมากขึ้นเมื่อเวลา
ผ่านไป

DEEP LEARNING

Deep learning breakthroughs
drive AI boom

การเรียนรู้เชิงลึก


ส่วนหนึ่งของการเรียนรู้ของเครื่อง
ที่นำโครงข่ายประสาทเทียม
มาเพิ่มการเรียนรู้ของชั้นข้อมูล
เพื่อให้แม่นยำขึ้น

1950's 1960's 1970's 1980's 1990's 2000's 2010's

ที่มา: สรุปจาก Copeland, 2016

WHY DEEP ?



- แบบจำลอง Deep learning (การเรียนรู้เชิงลึก) ประกอบด้วยจำนวนเซลล์ประสาทเทียมที่มีความซับซ้อนหลายชั้น ทำให้สามารถจดจำคุณลักษณะของข้อมูลที่ซับซ้อนได้




Source: <https://freecontent.manning.com/neural-network-architectures/>
<https://www.snexplores.org/article/explainer-what-is-a-neuron>

WHY DEEP ?

- แบบจำลองเชิงลึกสามารถแบ่งทำความเข้าใจข้อมูลเป็นลำดับขั้นได้





NEURAL NETWORK FUNDAMENTALS



PERCEPTRON

- Perceptron เป็นโครงข่ายประสาทเทียมที่มีการรับค่าข้อมูลเข้าและทำการรวมแบบถ่วงน้ำหนัก (Weighted sum) เปรียบได้กับสมการเส้นตรง และปรับขนาดของข้อมูลออกด้วยฟังก์ชันกระตุ้น (Activation function f)




Source: <https://th.wikipedia.org/wiki/โครงข่ายประสาทเทียม>
http://mlpy.sourceforge.net/docs/3.0/lin_class.html

$$\text{output} = f(\mathbf{x}w_0 + \mathbf{y}w_1 + \mathbf{z}w_2)$$



NEURAL NETWORK

- Neural network คือโครงข่ายประสาท ประกอบไปด้วย Perceptron หลายโหนด โดยสามารถมีได้หลายชั้น
- ชั้นแรกสุดคือชั้นข้อมูลเข้า (Input layer) ชั้นสุดท้ายคือชั้นข้อมูลออก (Output layer) และชั้นที่อยู่ระหว่างนั้นเรียกว่าชั้นซ่อน (Hidden layers)
- ฟังก์ชันกระตุ้นของชั้นซ่อนต้องเป็นฟังก์ชันที่ไม่เป็นเชิงเส้น เช่น Logistic function




NEURAL NETWORK (EMPIRICAL UNDERSTANDING)

- ตัวอย่างการแก้ปัญหาไม่เป็นเชิงเส้น โดย Neural Network ฟังก์ชันกระตุ้น Logistic function



มุมมองเชิงเส้น





ค่าที่ออกจากฟังก์ชันกระตุ้น


$$\text{out} = f(w_{10} + x_1 w_{11} + x_2 w_{12})$$

NEURAL NETWORK (EMPIRICAL UNDERSTANDING)

- ตัวอย่างการแก้ปัญหาไม่เป็นเชิงเส้น โดย Neural Network ฟังก์ชันกระตุ้น Logistic function



มุมมองเชิงเส้น





ค่าที่ออกจากฟังก์ชันกระตุ้น


$$\text{out} = f(w_{20} + x_1 w_{21} + x_2 w_{22})$$

NEURAL NETWORK (EMPIRICAL UNDERSTANDING)

- ตัวอย่างการแก้ปัญหาไม่เป็นเชิงเส้น โดย Neural Network ฟังก์ชันกระตุ้น Logistic function



มุมมองเชิงเส้น




ค่าที่ออกจากฟังก์ชันกระตุ้น


$$\begin{aligned} \text{out} = & w_{30} + f(w_{10} + x_1 w_{11} + x_2 w_{12}) w_{31} \\ & + f(w_{20} + x_1 w_{21} + x_2 w_{22}) w_{32} \end{aligned}$$

BACKWARD PROPAGATION


- การฝึกสอนโครงข่ายประสาทสามารถทำได้โดยใช้วิธีการแพร่ค่าความชันของค่าความเสียหาย (Loss) ย้อนหลัง (Back propagation) และปรับพารามิเตอร์ถ่วงน้ำหนัก (Weights) ของแบบจำลอง



ACTIVATION FUNCTIONS






NON-LINEAR ACTIVATION FUNCTIONS





WHY NON-LINEAR ACTIVATION FUNCTION

- หากไม่มีฟังก์ชันกระตุ้น หรือ ฟังก์ชันกระตุ้นมีลักษณะเป็นเชิงเส้นจะไม่สามารถสร้างคุณลักษณะของข้อมูลออกที่ไม่เป็นเชิงเส้น เนื่องจากค่าเชิงเส้นจะหักล้างกัน เหลือเพียงข้อมูลออกเชิงเส้นเท่านั้น (เส้นสีเขียว)




WHY NON-LINEAR ACTIVATION FUNCTION

- ด้วยการใส่คุณลักษณะที่ไม่เป็นเชิงเส้นในข้อมูลออกแต่ละโหนดทำให้สามารถสร้างคุณลักษณะไม่เป็นเชิงเส้นที่ซับซ้อนขึ้นได้



Q&A




EMPIRICAL STUDY

PLAYGROUND:

[HTTPS://PLAYGROUND.TENSORFLOW.ORG/](https://playground.tensorflow.org/)


1. LINEAR CLASSIFICATION

- ทดสอบ การจำแนกเชิงเส้นบนข้อมูลที่สามารถแยกออกจากกันได้เชิงเส้น
- ทดสอบกับ Activation function หลากๆแบบ ดูว่ามีความเปลี่ยนแปลง หรือไม่ ? เพราะอะไร ?




2. LINEAR CLASSIFICATION WITH NOISE

- ทดลองใส่ Noise เพื่อสังเกตพฤติกรรมของการเรียนรู้




3. LINEAR CLASSIFICATION CIRCLE DATA

- ทดสอบกับข้อมูลที่ไม่สามารถจำแนกออกจากกันได้เชิงเส้น




4. CORRECT FEATURE ENGINEERING

- การทำ Feature engineering (วิศวกรรมคุณลักษณะ) ที่ถูกต้อง ส่งผลให้แบบจำลองเชิงเส้นสามารถจำแนกข้อมูลดังกล่าวได้



5. FEATURE EXTRACTION BY DEEPER MODEL


- ทดสอบการใช้ Neural network ในการทำ Feature engineering โดยการเพิ่ม 1 Hidden layer ที่ประกอบด้วย 3 Hidden nodes ส่งผลใกล้เคียงกับการทำ Feature engineering ที่ถูกต้องโดยเกิดจากเส้นตรง 3 เส้น



ทดลอง Activation Function อื่นๆ


6. MORE PROBLEM COMPLEXITY

- ลักษณะของข้อมูลมีความซับซ้อนเกินกว่าจะใช้สมการเส้นตรง 8 เส้นจะสามารถจำแนกคลาสของข้อมูลได้ถูกต้อง




7. MORE MODEL COMPLEXITY

- การเพิ่มจำนวนชั้นซ่อนของข้อมูลเพื่อเพิ่มความซับซ้อนของการทำ Feature engineering ทำให้แบบจำลองเกาะกับข้อมูลได้มากขึ้น



8. NOT ENOUGH COMPLEXITY (UNDER FITTING)


- หากมีจำนวน Hidden layers ไม่เพียงพอกับความซับซ้อนของปัญหา จะทำให้แบบจำลองไม่สามารถทำการสกัดคุณลักษณะที่เหมาะสมในการจำแนกข้อมูลดังกล่าวได้ เกิดเป็นปัญหา การฟิตต่ำเกินไป Under fitting



9. OVER FITTING


- หากแบบจำลองมีความซับซ้อนมากเกินไป
- ข้อมูลฝึกสอนมีปริมาณน้อย
- ข้อมูลที่เป็นสัญญาณรบกวน (Noise)
- จะทำให้แบบจำลองพยายามปรับตัวให้มีความเข้ากับสัญญาณรบกวนหรือปรับเข้ากับข้อมูลเป็นรายตัว แทนที่จะเป็น การเรียนรู้ลักษณะ (Pattern) ของปัญหานั้น
- เกิดเป็นปัญหาการฟิตเกิน (Over fitting) ทำให้แบบจำลองมีการวางนัยทั่วไป (Generalization) ต่ำ และค่าความเสียหายบนข้อมูลทดสอบสูง
- สามารถใช้หลักการ Regularization ในการปรับลดความซับซ้อนของแบบจำลองได้

9. OVER FITTING



With-Out Regularization


9. OVER FITTING



With Regularization

Q&A

DEEP LEARNING APPLICATIONS




AUTONOMOUS VEHICLES

- รถยนต์ไร้คนขับ ต้องใช้เทคโนโลยีหลายชนิดเพื่อเป็นข้อมูลสำหรับการตัดสินใจในการขับอัตโนมัติ

Object segmentation





Lane detection



Source: <https://www.xpertup.com/downloads/advanced-lane-detection/>

VISUAL INSPECTION




GENERATE IMAGES FROM TEXT

- สร้างรูปภาพให้สอดคล้องกับคำหรือประโยคที่ป้อนเข้าไป โดยใช้หลักการของการประมวลผลเชิงลึกกับข้อความเพื่อสรุปสาระสำคัญ และนำไปสร้างข้อมูลภาพ

- Midjourney <https://www.midjourney.com/>
- Artbreeder <https://www.artbreeder.com/>
- WaifuLabs <https://waifulabs.com/generate>
- Disco Diffusion <http://discodiffusion.com>
- Nvidia canvas <https://www.nvidia.com/en-us/studio/canvas/>

DALL·E mini by craiyon.com

AI model generating images from any prompt!



Source: <https://huggingface.co/spaces/dalle-mini/dalle-mini>

GENERATE IMAGES FROM TEXT

- Rising sea level London, climate change, future in fifty years




– Midjourney

<https://www.midjourney.com/>

PHOTOSHOP GENERATIVE FILL

สร้างภาพจากข้อความ



Source: <https://techsauce.co/news/photoshop-add-new-ai-feature-generative-fill>

<https://www.youtube.com/watch?v=IVTyLYupECI>

CHAT GPT

- โมเดลภาษาปัญญาประดิษฐ์ขั้นสูงที่พัฒนาโดย OpenAI ChatGPT ใช้โครงข่ายประสาทเทียมที่มีพารามิเตอร์ 1.75 แสนล้านพารามิเตอร์ที่ช่วยให้สร้างการตอบสนองต่อคำถามและคำสั่งที่หลากหลายได้เหมือนมนุษย์



Source: <https://www.amitysolutions.com/>


ALPHA GO

- การเรียนรู้เชิงลึกควบคู่กับการเรียนรู้แบบเสริมกำลัง (Reinforcement learning) และแก้ไขข้อผิดพลาดจากการเล่นหลายเกมจนสามารถสร้างแบบจำลองที่เรียนรู้รูปแบบการเล่นที่ชนะแชมป์โลกได้





Q&A




CNN: CONVOLUTIONAL NEURAL NETWORK

WHY WE SHOULD NOT USE DENSE WITH IMAGE






WHY WE SHOULD NOT USE DENSE WITH IMAGE

- Dense layer มีลักษณะเด่นคือในแต่ละ Layer ที่เชื่อมต่อกันจะมี weight เชื่อม node จาก Layer ก่อนหน้าไปยัง Layer ถัดไปทุกๆ node เสมอทำให้ได้ weight เฉพาะสำหรับแต่ละตัวแปร ทำให้แบบจำลองเน้นไปที่คุณลักษณะเฉพาะของตัวแปรนั้นๆ
- การประมวลผลภาพจะมีรูปแบบการจดจำเป็นตำแหน่ง Pixel เช่น ถ้าข้อมูลฝึกสอนมีภาพไฟจราจรด้านบนฝั่งขวา แต่หากไปเจอรูปภาพที่ด้านบนฝั่งซ้ายจะทำให้แบบจำลองเกิดข้อผิดพลาดได้
- ตำแหน่งวัตถุที่ต่างกันอาจถูกประมวลผลเป็นคนละชนิดได้




WHY WE SHOULD NOT USE DENSE WITH IMAGE



CONVOLUTIONAL LAYERS

- Convolutional layer ใช้หลักการการแชร์ตัวถ่วงน้ำหนัก (Weight sharing)
- ข้อมูล 3 ชุด เรียงจากซ้ายไปขวาคือ ข้อมูลเข้า เคอร์เนล (Kernel หรือตัวถ่วงน้ำหนัก) และข้อมูลออก



KERNEL AND WEIGHT SHARING

- เคอร์เนลของ Convolutional layer มักมีขนาดเล็กกว่าขนาดข้อมูลเข้า (แผ่นสี่เหลี่ยม) และใช้การเลื่อน (Stride) จากซ้ายไปขวา และจากบนลงล่าง ให้ครอบคลุมข้อมูลเข้าทั้งหมด
- ทำให้แต่ละส่วนของข้อมูลเข้าถูกประมวลผลด้วยตัวถ่วงน้ำหนักชนิดเดียวกัน แก้ปัญหาที่วัตถุอยู่คนละตำแหน่ง

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0


Image

4		

Convolved
Feature


INPUT AND OUTPUT CHANNELS

- หากข้อมูลเข้าเป็นรูปภาพที่มีความกว้าง W และสูง H ช่องสัญญาณ (Channels) ของข้อมูลคือความลึก ที่เปรียบได้กับค่าสี R, G, B ของรูปภาพนั่นเอง
- สำหรับข้อมูลเข้าที่มี 3 channels จะต้องใช้ Kernel ขนาด $KW \times KH \times 3$ เพื่อที่จะได้ข้อมูลออก 1 Channel โดยหากต้องการข้อมูลออกที่มีขนาด 4 Channels จะต้องใช้ Kernel ดังกล่าว จำนวน 4 ชุด นั่นคือขนาดของ Kernel เท่ากับ $4 \times KW \times KH \times 3$ นั่นเอง
- การเพิ่มจำนวน Channel เปรียบได้กับการเพิ่มจำนวน Node ของ Neural network ให้มีความซับซ้อนมากขึ้น




PADDING AND STRIDE

- Padding คือการเพิ่มขอบของรูปภาพ (หรือข้อมูลอื่นๆ) ด้วยข้อมูลที่เป็นเลข 0 เพื่อเพิ่มขนาดของข้อมูลให้ เป็นไปตามที่ต้องการ
- Stride คือการเลื่อนตำแหน่ง Kernel ตามระยะ S




POOLING LAYERS

- Pooling layers มีหน้าที่ในการลดขนาดข้อมูล โดยการดึงข้อมูลที่มีลักษณะเด่นออกมา (Sub sample) จากข้อมูลใกล้เคียงกัน โดยฟังก์ชันที่นิยมใช้กันได้แก่ Max pooling คือการดึงข้อมูลที่มีค่าการกระตุ้นสูงที่สุดจากข้อมูลใกล้เคียง
- Max pooling นอกจากจะลดขนาดข้อมูลที่ต้องประมวลผลแล้วยังทำให้แบบจำลองเกิดคุณสมบัติความเบาบาง (Sparse) เพิ่มคุณลักษณะความไม่เป็นเส้นตรงให้กับแบบจำลองอีกด้วย




RECEPTIVE FIELD

- Max pooling (Max subsample) ทำให้เกิดการกระจายตัวของ Receptive field ซึ่งทำให้แบบจำลองพิจารณาข้อมูลทั่วถึงทั้งภาพมากยิ่งขึ้น
- Receptive field (พื้นที่การรับรู้) คือ พื้นที่ที่แบบจำลองทำการพิจารณาบนข้อมูลเข้า เพื่อใช้ในการจำแนกหรือทำนาย หาก Receptive field กระจุกอยู่ที่ตำแหน่งใดเป็นพิเศษแสดงว่าพื้นที่นั้นส่งผลต่อข้อมูลออก (output) อย่างมาก



Conv-Only



Subsample

Receptive Field

DROPOUT LAYERS


- Dropout คือการสุ่มเปลี่ยนค่าข้อมูลในบางตำแหน่งให้มีค่าเป็น 0 เสมือนเป็นการลบข้อมูลนั้นออกไป
- ช่วยให้ข้อมูลมีความบาง (Sparse) มากขึ้น
- ลด ตัวแปรที่มีการปรับเปลี่ยนตามกัน (Co-Adaptive variable)
- ทำให้ข้อมูลมีรูปแบบที่หลากหลาย ทำให้แบบจำลองมีการวางนัยทั่วไปเพิ่มขึ้น

4	2	-1	3	1
2	0	5	-4	2
-7	3	3	0	1
2	6	2	-8	-5




4	0	-1	3	0
2	0	5	0	2
-7	3	3	0	1
0	6	0	-8	-5


CNN STRUCTURE



Q&A




EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION




Source: https://e2eml.school/how_convolutional_neural_networks_work.html

EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION




EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION




Source: https://e2eml.school/how_convolutional_neural_networks_work.html

EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION




Source: https://e2eml.school/how_convolutional_neural_networks_work.html


EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION



EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION




EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION



Source: https://e2eml.school/how_convolutional_neural_networks_work.html


EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION

Pooling



Source: https://e2eml.school/how_convolutional_neural_networks_work.html


EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION



Source: https://e2eml.school/how_convolutional_neural_networks_work.html


EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION

Apply ReLU Activation function



EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION


Apply ReLU Activation function



Source: https://e2eml.school/how_convolutional_neural_networks_work.html



EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION

Whole Deep learning Structure



Source: https://e2eml.school/how_convolutional_neural_networks_work.html

EMPIRICAL EXAMPLE X' AND O' CLASSIFICATION



Source: https://e2eml.school/how_convolutional_neural_networks_work.html

PLAYGROUND TEACHABLE MACHINE



- <https://teachablemachine.withgoogle.com/>

Teachable Machine

Train a computer to recognize your own images, sounds, & poses.


A fast, easy way to create machine learning models for your sites, apps, and more – no expertise or coding required.

Get Started



PLAYGROUND TEACHABLE MACHINE

The screenshot displays the Playground Teachable Machine interface. On the left, there are two class sample areas: 'Class 1' with two cat images and 'Class 2' with two dog images. Each class has 'Webcam' and 'Upload' buttons. Below these is an 'Add a class' button. In the center, the 'Training' panel shows 'Model Trained' status, 'Advanced' settings (Epochs: 50, Batch Size: 16, Learning Rate: 0.001), and 'Under the hood' options. On the right, the 'Preview' panel shows an 'Input' toggle set to 'ON', a 'File' dropdown, and a cat image. Below the image, the 'Output' section shows 'Class 1' with a 99% confidence bar and 'Class 2' with a 0% confidence bar. An arrow points from the 'Export Model' button in the Preview panel to the right, leading to the model architecture diagram.



Q&A

The background of the slide is a photograph of a wireframe cube constructed from thin metal rods and small spherical joints, resting on a dark, textured surface. The cube is positioned diagonally, with its front face partially visible. The lighting creates highlights on the metal joints and rods, giving it a three-dimensional appearance. A dark, semi-transparent rectangular box is overlaid on the left side of the image, containing the title text.

OBJECT DETECTION CONCEPT

OBJECT DETECTION CONCEPT

Classification



Dog

Localization




Detection




Dog

BOUNDING BOX AND CLASS




IOU

- การหาอัตราพื้นที่ร่วมกันของกล่อง สามารถใช้ตัวชี้วัด IoU (Intersection over Union) เพื่อตรวจสอบว่ากล่องขอบเขต (Bounding boxes) 2 กล่องนั้นมีพื้นที่ทับซ้อนกันมากแค่ไหน
- พื้นที่ที่ทับซ้อนกัน (Intersection area) หารด้วยพื้นที่ทั้งหมด (Union area)



IoU = 0



IoU = 0.142




IoU = 0.333



IoU = 1

SIMPLE NETWORK STRUCTURE

- Output ของแบบจำลองมีลักษณะเป็น 3 มิติ คือ กว้าง สูง และช่องสัญญาณ
- ช่องสัญญาณจะนำไปใช้เป็น parameters สำหรับ ตำแหน่งศูนย์กลางกล่อง, ขนาดกล่อง และ คลาส





Q&A