




9.1 เครื่องมือวิทยาการข้อมูล: Rapidminer

Tools for Data Science: Rapidminer – Regression2

ดำรงฤทธิ์ เศรษฐศิริโชค

Regression LAB 2

- Multiple Linear Regression
- Generalize Linear Model: GLM
- Regularization
- Loop Parameters



house_price.xlsx



ID Number	price Number	bedroom Number	bathroom Number	house_type Category	lot_size Number	built_in Number	area Number	days Number	views Number
993	229900	3	2	single-family home	10018	2002	1541	77	1357
994	149900	4	2	single-family home	8712	1975	1810	5	1282
995	229900	3	2	single-family home	13504	1988	1456	76	947
996	359000	5	4	single-family home	10130	1997	2903	79	951
999	394000	3	2	single-family home	18295	2001	2616	73	709
1000	349900	3	2	single-family home	204732	1967	3850	42	366
1002	349900 148500	3	1	single-family home	9147	1959	1000	17	328
1003	134900	2	2	townhouse	2300	1994	920	56	328
1004	265000	3	3	single-family home	13939	1998	2705	12	362
1005	149900	4	3	townhouse	2291	1999	1440	4	137
1006	429000	4	5	single-family home	7405	2017	2799	75	569
1007	309900	3	3	single-family home	15246	1986	2136	6	173
1010	699900	5	6	single-family home	18295	2007	5955	75	100

สำรวจและทำความเข้าใจข้อมูล

Retrieve house_price



Select Attributes



Select Attributes: attributes

Select Attributes: **attributes**
The attribute which should be chosen.

Attributes

Search

- # built_in
- # days
- # house_type
- # ID
- # views

Selected Attributes

Search

- # area
- # bathroom
- # bedroom
- # lot_size
- # price

Apply Cancel

Plot

Plot 1

Plot type

Scatter Matrix

Value columns

bedroom, bathroom, l..

Color

-

Column Summary

Histogram

Chart size

Plot style

Add new plot

General

X-Axis

Y-Axis


Title

Legend

Tooltip



สำรวจและทำความเข้าใจข้อมูล




Result History

Correlation Matrix (Correlation Matrix)

Attributes	price	bedroom	bathroom	lot_size	area
price	1	0.389	0.321	0.765	0.484
bedroom	0.389	1	0.644	-0.104	0.745
bathroom	0.321	0.644	1	-0.238	0.786
lot_size	0.765	-0.104	-0.238	1	-0.110
area	0.484	0.745	0.786	-0.110	1

สร้างการเรียนรู้จากแบบจำลอง Linear Regression




ผลลัพธ์แบบจำลอง


 PerformanceVector (Performance Test) 	 LinearRegression (Linear Regression) 	 PerformanceVector (Performance Train) 
--	--	---

Attribute	Coefficient	Std. Error	Std. Coefficient	Tolerance	t-Stat	p-Value
bedroom	28259.186	18044.603	0.112	0.911	1.566	0.132
bathroom	27902.386	13704.377	0.157	0.961	2.036	0.054
lot_size	0.198	0.012	0.868	0.945	16.368	0.000
area	51.494	15.642	0.298	0.868	3.292	0.003
days	779.961	519.041	0.100	0.996	1.503	0.147
views	-82.697	41.879	-0.143	0.833	-1.975	0.061
(Intercept)	17833.133	55369.500	?	?	0.322	0.750

ผลลัพธ์ประสิทธิภาพ




ค่า R-square จากข้อมูลชุด train กับ test
ต่างกันมาก --> over fitting



ทดลองแก้ปัญหาด้วย Regularization

เปลี่ยนแบบจำลองเป็น GLM



GLM

- ทดลองการสร้างแบบจำลอง GLM
- w/ and w/o standardize
- w/ and w/o regularization
- alpha L1 / L2
- ทดลองและสังเกตผลลัพธ์

Parameters ✕

 **Generalized Linear Model**

family

solver

☐ reproducible ⓘ

☒ use regularization ⓘ

lambda

☐ lambda search ⓘ

alpha

☒ standardize ⓘ


☐ non-negative coefficients ⓘ

☒ add intercept ⓘ

☐ remove collinear columns ⓘ


missing values handling ⓘ


Generalized Linear Model




Loop Parameters

- สำหรับทำกระบวนการย่อยภายใน
- สร้างการทดลองโดยปรับค่า parameter บางตัว







Select Parameters: configure operator

Select Parameters: **configure operator**
Configure this operator by means of a Wizard.

Operators

- Split Data (Split Data)
- Generalized Linear Model (Generalized Linear Model)**
- Multiply (Multiply)
- Apply Model Test (Apply Model)
- Performance Test (Performance (Regression))
- Apply Model Train (Apply Model)
- Performance Train (Performance (Regression))

Parameters

- maximum_number_of_threads
- use_regularization
- lambda_search
- number_of_lambdas
- lambda_min_ratio
- early_stopping
- stopping_rounds
- stopping_tolerance

Selected Parameters

- Generalized Linear Model.lambda**

Grid/Range

Min	Max	Steps	Scale
0.0001	999999999	1000	logarithmic

Value List


	0.000
	0.000
	0.000
	0.000
	0.000
	0.000
	0.000
	0.000
	0.000
	0.000

☒ Grid ☐ List

1 parameter / 1001 combinations selected

☒ OK ☐ Cancel

เพิ่ม Log ภายใน Loop



วิเคราะห์ผลลัพธ์

- ผลลัพธ์จาก Log บันทึก R-square ที่ได้จากการปรับ lambda แต่ละครั้ง

Result History

 IOObjectCollection (Loop Parameters)

Log

 Data

Log (1001 rows, 3 columns)


R-square Train	R-square Test	Lambda
0.957	0.796	0.001
0.957	0.796	0.004
0.957	0.797	316.228
0.000	0.000	56234...
0.957	0.796	0.000
0.957	0.796	0.178
0.957	0.796	0.002
0.000	0.000	57942...
0.957	0.796	0.004
0.957	0.796	0.001
0.957	0.797	325.837
0.957	0.796	0.001

 Simple Charts

 Advanced Charts

วิเคราะห์ผลลัพธ์

ทดลองเพิ่ม RMSE ใน Log



ทดลอง

- sin_noisy20
- sin_noisy40
- sin_noisy80

Q & A