




11. กระบวนการเรียนรู้แบบไม่มีผู้ฝึกสอน

Unsupervised Learning Processes

ดำรงฤทธิ์ เศรษฐศิริโชค

กระบวนการเรียนรู้แบบไม่มีผู้ฝึกสอน

การวิเคราะห์ความสัมพันธ์ (Association Analysis)

การแบ่งกลุ่ม (Clustering)

การตรวจจับความผิดปกติ (Anomaly Detection)




Table 1.1 Data Mining Tasks and Examples

Tasks	Description	Algorithms	Examples
Classification	Predict if a data point belongs to one of the predefined classes. The prediction will be based on learning from a known data set.	Decision trees, neural networks, Bayesian models, induction rules, k-nearest neighbors	Assigning voters into known buckets by political parties, e.g., soccer moms Bucketing new customers into one of the known customer groups
Regression	Predict the numeric target label of a data point. The prediction will be based on learning from a known data set.	Linear regression, logistic regression	Predicting unemployment rate for next year Estimating insurance premium
Anomaly detection	Predict if a data point is an outlier compared to other data points in the data set.	Distance based, density based, local outlier factor (LOF)	Fraud transaction detection in credit cards Network intrusion detection
Time series	Predict the value of the target variable for a future time frame based on historical values.	Exponential smoothing, autoregressive integrated moving average (ARIMA), regression	Sales forecasting, production forecasting, virtually any growth phenomenon that needs to be extrapolated
Clustering	Identify natural clusters within the data set based on inherent properties within the data set.	k-means, density-based clustering (e.g., density-based spatial clustering of applications with noise [DBSCAN])	Finding customer segments in a company based on transaction, web, and customer call data
Association analysis	Identify relationships within an item set based on transaction data.	Frequent Pattern Growth (FP-Growth) algorithm, Apriori algorithm	Find cross-selling opportunities for a retailer based on transaction purchase history

การวิเคราะห์ความสัมพันธ์

- พิจารณาความหนาแน่นของการเกิดเหตุการณ์ร่วมกัน (co-occurrence)
- ค้นหาแบบที่ซ่อนอยู่ที่ทำให้เกิดเหตุการณ์ร่วมกัน
- สร้างกฎความสัมพันธ์
- การวิเคราะห์ตะกร้าสินค้า (Market basket analysis) นำไปสู่
 - จับคู่สินค้า
 - เสนอสินค้าใหม่ที่ใกล้เคียง
 - เพิ่มกลยุทธ์การขายต่างๆ
- เหตุการณ์หรือข้อมูลที่มีมากขึ้นใกล้กัน
- Apriori, FP-GROWTH

NETFLIX



การวิเคราะห์ความสัมพันธ์

$$\{\text{Item A}\} \rightarrow \{\text{Item B}\}$$

- Set Item A = premise
- Set Item B = consequent, conclusion
- ภายใน Set มีสมาชิกมากกว่า 1 ได้

การสร้างกฎความสัมพันธ์

- Step 1: เก็บ/เตรียมข้อมูล
- Step 2: สร้าง **itemsets** ความถี่ จากการเกิดขึ้นของ item ใน set
- Step 3: สร้างกฎความสัมพันธ์ (relevant) จาก itemsets
- ตัวอย่าง: เริ่มต้นเก็บข้อมูลหัวข้อในการเข้าถึงเว็บจากผู้ใช้ทุกๆ 30 นาที

Table 6.1 Clickstream

Session ID	List of Media Categories Accessed
1	{News, Finance}
2	{News, Finance}
3	{Sports, Finance, News}
4	{Arts}
5	{Sports, News, Finance}
6	{News, Arts, Entertainment}

สร้างชุดข้อมูล

Table 6.1 Clickstream

Session ID	List of Media Categories Accessed
1	{News, Finance}
2	{News, Finance}
3	{Sports, Finance, News}
4	{Arts}
5	{Sports, News, Finance}
6	{News, Arts, Entertainment}

Table 6.2 Clickstream Dataset

Session ID	News	Finance	Entertainment	Sports	Arts
1	1	1	0	0	0
2	1	1	0	0	0
3	1	1	0	1	0
4	0	0	0	0	1
5	1	1	0	1	0
6	1	0	1	0	1

สร้าง Itemsets

Table 6.1 Clickstream

Session ID	List of Media Categories Accessed
1	{News, Finance}
2	{News, Finance}
3	{Sports, Finance, News}
4	{Arts}
5	{Sports, News, Finance}
6	{News, Arts, Entertainment}

- ตัวอย่างการสร้าง Itemsets สามารถพิจารณาจากหลาย Item
- เช่น “If users visited the **Finance** page they are more likely to visit the **News and Sports** pages”
- ความเข้มข้นของกฎขึ้นอยู่กับค่า support และ confidence

Itemsets

{News, Finance} → {Sports}

Support

Table 6.2 Clickstream Dataset					
Session ID	News	Finance	Entertainment	Sports	Arts
1	1	1	0	0	0
2	1	1	0	0	0
3	1	1	0	1	0
4	0	0	0	0	1
5	1	1	0	1	0
6	1	0	1	0	1

- ค่าการสนับสนุน item (*support of an item*) ตามความถี่ที่เกิดขึ้นของ Itemsets

$$\text{Support}(\{\text{News}\}) = 5/6 = 0.83$$

$$\text{Support}(\{\text{News}, \text{Finance}\}) = 4/6 = 0.67$$

$$\text{Support}(\{\text{Sports}\}) = 2/6 = 0.33$$

- ค่าการสนับสนุนกฎ (*support of a rule*) ตามรายการในกฎเทียบกับรายการทั้งหมด
 $\{\text{News}\} \rightarrow \{\text{Sports}\}$ เกิดขึ้น 2 ใน 6 รายการ = $2/6 = 0.33$

Confidence

- confidence of a rule ตัววัดความเป็นไปได้ที่จะเกิดขึ้นของ consequence เทียบกับทุกรายการที่ประกอบด้วยเซตที่เกิดขึ้นก่อนของกฎนั้น

- พิจารณา {News, Finance} --> {Sports}

Table 6.2 Clickstream Dataset

Session ID	News	Finance	Entertainment	Sports	Arts
1	1	1	0	0	0
2	1	1	0	0	0
3	1	1	0	1	0
4	0	0	0	0	1
5	1	1	0	1	0
6	1	0	1	0	1

$$\text{Confidence } (X \rightarrow Y) = \frac{\text{Support } (X \cup Y)}{\text{Support } (X)}$$

$$\begin{aligned}
 \text{Confidence } (\{\text{News, Finance}\} \rightarrow \{\text{Sports}\}) &= \frac{\text{Support } (\{\text{News, Finance, Sports}\})}{\text{Support } (\{\text{News, Finance}\})} \\
 &= \frac{2/6}{4/6} \\
 &= 0.5
 \end{aligned}$$

- ตีความได้ว่า 50% ของผู้ใช้ที่เข้าถึง {News, Finance} จะเข้าถึง {Sports} ด้วย

Lift

- เพิ่มการพิจารณาน้ำหนักของ consequence ในกรณี consequence เกิดขึ้นน้อยมาก จะทำให้ค่า lift ใกล้เคียง 1 ซึ่งอาจสามารถมองข้ามกฎนั้นไปได้

Table 6.2 Clickstream Dataset

Session ID	News	Finance	Entertainment	Sports	Arts
1	1	1	0	0	0
2	1	1	0	0	0
3	1	1	0	1	0
4	0	0	0	0	1
5	1	1	0	1	0
6	1	0	1	0	1

$$\text{Life } (X \rightarrow Y) = \frac{\text{Support } (X \cup Y)}{\text{Support } (X) \times \text{Support } (Y)}$$

In the case of our example:

$$\begin{aligned} \text{Life } (\{\text{News, Finance}\} \rightarrow \{\text{Sports}\}) &= \frac{\text{Support } (X \cup Y)}{\text{Support } (X) \times \text{Support } (Y)} \\ &= \frac{0.333}{0.667 \times 0.33} = 1.5 \end{aligned}$$

- Lift ยิ่งค่ามาก กฎยิ่งมีน้ำหนักมาก

The Apriori and Frequent Pattern (FP)-Growth

- หากข้อมูลขนาดใหญ่ จำเป็นต้องสร้างกฎจำนวนมาก
- ใช้อัลกอริทึมช่วย
- 2 อัลกอริทึมที่นิยม

Apriori

Frequent Pattern (FP)-Growth





FIGURE 6.1
Itemset tree.

Support {News, Finance, Sports} = 0.33 (above threshold support)
 Support {News, Finance} = 0.66
 Support {News, Sports} = 0.33
 Support {News} = 0.83
 Support {Sports} = 0.33
 Support {Finance} = 0.66



- ในทางตรงกันข้าม ถ้า itemset ใด
ความถี่น้อย subset จะถูก
พิจารณาความถี่น้อยตาม

FIGURE 6.2

Frequent itemsets using Apriori principle.

- ถ้า itemset ใดมีความถี่น้อย superset จะถูกพิจารณาความถี่น้อยตาม
- ในกรณีนี้ $\text{support}(\{\text{Entertainment}\})$ อยู่ที่ $1/6 = 0.167$ หากกำหนด $\text{threshold} = 0.25$ กรณีนี้จะถูกตัดทิ้งในการทำงานรอบถัดไป
- ตัวอย่างนี้ ตัด Entertainment และ Art





FIGURE 6.3

Frequent itemsets using Apriori principle: exclusion.

- สร้างกฎที่เป็นไปได้ที่เหลือคือ $2^n - 2$
- คำนวณค่า confident



$\{\text{News, Sports}\} \rightarrow \{\text{Finance}\} - 0.33/0.33 = 1.0$
 $\{\text{News, Finance}\} \rightarrow \{\text{Sports}\} - 0.33/0.67 = 0.5$
 $\{\text{Sports, Finance}\} \rightarrow \{\text{News}\} - 0.33/0.33 = 1.0$
 $\{\text{News}\} \rightarrow \{\text{Sports, Finance}\} - 0.33/0.83 = 0.4$
 $\{\text{Sports}\} \rightarrow \{\text{News, Finance}\} - 0.33/0.33 = 1.0$
 $\{\text{Finance}\} \rightarrow \{\text{News, Sports}\} - 0.33/0.67 = 0.5$

FIGURE 6.4

Frequent itemset with support.

FREQUENT PATTERN-GROWTH ALGORITHM: FP-GROWTH

- ใช้ FP-Tree แปลงชุดข้อมูลไปกราฟเพื่อสร้าง Itemsets
- จากข้อมูลเดิม (6 รายการ 4 Item)

Table 6.5 Transactions List: Session and Items	
Session	Items
1	{News, Finance}
2	{News, Finance}
3	{News, Finance, Sports}
4	{Sports}
5	{News, Finance, Sports}
6	{News, Entertainment}




FIGURE 6.5

FP-Tree: Transaction 1.




FIGURE 6.5
FP-Tree: Transaction 1.

Table 6.5 Transactions List: Session and Items	
Session	Items
1	{News, Finance}
2	{News, Finance}
3	{News, Finance, Sports}
4	{Sports}
5	{News, Finance, Sports}
6	{News, Entertainment}




FIGURE 6.6
FP-Tree: Transactions 1–3.




FIGURE 6.7
FP-Tree: Transactions 1–6.

Frequent Itemset Generation

- ปลายสุดของ FP-tree สื่อถึง support คำน้อยจะถูกตัดออก
- สร้าง Itemsets ตามลำดับต้นไม้




FIGURE 6.7

FP-Tree: Transactions 1–6.





FIGURE 6.8

Trimmed FP-Tree.

Rapidminer process for FP-Growth algorithm



Result History

FrequentItemSets (FP-Growth) ×

No. of Sets: 8
Total Max. Size: 3

Min. Size:

Max. Size:

Contains Item:

Update View

Size	Support	Item 1	Item 2	Item 3
1	0.833	News		
1	0.667	Finance		
1	0.333	Arts		
1	0.333	Sports		
2	0.667	News	Finance	
2	0.333	News	Sports	
2	0.333	Finance	Sports	
3	0.333	News	Finance	Sports

FrequentItemSets (FP-Growth) ×

No.	Premises	Conclusion	Support	Confidence	LaPlace	Gain	p-s	Lift	Convic...
3	Finance	Sports	0.333	0.500	0.800	-1	0.111	1.500	1.333
4	Finance	News, Sports	0.333	0.500	0.800	-1	0.111	1.500	1.333
5	News, Finance	Sports	0.333	0.500	0.800	-1	0.111	1.500	1.333
6	News	Finance	0.667	0.800	0.909	-1	0.111	1.200	1.667
7	Finance	News	0.667	1	1	-0.667	0.111	1.200	∞
8	Sports	News	0.333	1	1	-0.333	0.056	1.200	∞
9	Sports	Finance	0.333	1	1	-0.333	0.111	1.500	∞
10	Sports	News, Finance	0.333	1	1	-0.333	0.111	1.500	∞
11	News, Sports	Finance	0.333	1	1	-0.333	0.111	1.500	∞
12	Finance, Sports	News	0.333	1	1	-0.333	0.056	1.200	∞



Exercise: Association

การวิเคราะห์ความสัมพันธ์

Dataset: imdb_labelled.csv

Dataset: reddit.csv

** ต้องใช้ Nominal to Text operator

Q & A

การแบ่งกลุ่ม

Clustering

การแบ่งกลุ่ม

- ใช้แยกกลุ่มข้อมูลแบบไม่มีผู้ฝึกสอน
- การใช้งานเช่น
การตลาด: แยกกลุ่มลูกค้า แบ่งระดับลูกค้า
เอกสาร: จัดกลุ่มเอกสารชนิดใกล้เคียงกัน
ข้อมูลการใช้งานระบบต่างๆ เพื่อทำความเข้าใจพฤติกรรม

ชนิดการแบ่งกลุ่ม

- Exclusive or strict partitioning clusters แบ่งกลุ่มข้อมูลแยกจากกันชัดเจน
- Overlapping clusters ข้อมูลเดียวกันอยู่ได้หลายกลุ่ม
- Hierarchical clusters แบ่งตามลำดับชั้น ชั้นล่างเป็นผลจากการรวมกันของชั้นบน
- Fuzzy or probabilistic clusters ข้อมูลสามารถอยู่กับทุกกลุ่มโดยการกำหนดระดับ degree เช่น มีกลุ่ม A-B-C-D ข้อมูลสามารถถูกกำหนดเป็น $A=0.5$, $B=0.1$, $C=0.4$, และ $D=0$





FIGURE 7.1

Example of a clustering of the Iris dataset without class labels.

K-MEANS CLUSTERING

- นิยมใช้ Euclidean distance เพื่อตรวจสอบระยะห่างจาก Centroids






FIGURE 7.5
Initial random centroids.





FIGURE 7.6
Assignment of data points to nearest centroids.




FIGURE 7.7
New centroids.





FIGURE 7.8
Assignment of data points to new centroids. จนกว่าค่าจะไม่เปลี่ยน

ทดลอง Auto Model กับข้อมูล Iris

Auto Model

Load Data

Select Task

Prepare Target

Select Inputs

Model Types

Results

« RESTART < BACK > NEXT

Predict
Want to predict the values of a column?

Clusters
Want to identify groups in your data?

Outliers
Want to detect outliers in your data?

a1 Number	a2 Number	a3 Number	a4 Number	id Category	label Category
5.100	3.500	1.400	0.200	id_1	Iris-setosa
4.900	3	1.400	0.200	id_2	Iris-setosa
4.700	3.200	1.300	0.200	id_3	Iris-setosa
4.600	3.100	1.500	0.200	id_4	Iris-setosa
5	3.600	1.400	0.200	id_5	Iris-setosa
5.400	3.900	1.700	0.400	id_6	Iris-setosa
4.600	3.400	1.400	0.300	id_7	Iris-setosa
5	3.400	1.500	0.200	id_8	Iris-setosa
4.400	2.900	1.400	0.200	id_9	Iris-setosa
4.900	3.100	1.500	0.100	id_10	Iris-setosa
5.400	3.700	1.500	0.200	id_11	Iris-setosa
4.800	3.400	1.600	0.200	id_12	Iris-setosa
4.800	3	1.400	0.100	id_13	Iris-setosa

150 rows - 6 columns (4 numerical)

ทดลอง Auto Model กับข้อมูล Iris

Results

▼ k-Means

Summary

Heat Map

Cluster Tree

Centroid Chart

Centroid Table

Scatter Plot

Clustered Data

▼ i General

Data

Statistics

Correlations



SAVE RESULTS

k-Means – Scatter Plot

Focus on Cluster:

Cluster 2 ▼

Jitter Amount:



ทดลองข้อมูล

Mall_Customers.csv

Predict

Want to predict the values of a column?

Clusters


Want to identify groups in your data?

Outliers

Want to detect outliers in your data?

CustomerID <i>Number</i>	Gender <i>Category</i>	Age <i>Number</i>	Annual Income (k\$) <i>Number</i>	Spending Score (1-100) <i>Number</i>
1	Male	19	15	39
2	Male	21	15	81
3	Female	20	16	6
4	Female	23	16	77
5	Female	31	17	40
6	Female	22	17	76
7	Female	35	18	6
8	Female	23	18	94
9	Male	64	19	3
10	Female	30	19	72
11	Male	67	19	14
12	Female	35	19	99
13	Female	58	20	15
14	Female	24	20	77
...	...	...	...	...

ทดลองสร้างกระบวนการแบ่งกลุ่ม



การตรวจจับความผิดปกติ

Anomaly Detection

การตรวจจับความผิดปกติ



- กระบวนการตรวจหาค่าผิดปกติ (Outlier) ภายในชุดข้อมูล
- ถูกใช้ในการวิเคราะห์ข้อมูลหลายสาขาเช่น ธุรกิจ วิทยาศาสตร์ และความปลอดภัยเครือข่าย (การโจมตีทาง cyber มีการใช้งานผิดปกติ) เป็นต้น
- ใช้เทคนิคการจำแนก การถดถอย หรือการแบ่งกลุ่มก็สามารถสร้างกระบวนการตรวจจับค่าผิดปกติได้ หากผลลัพธ์หรือผลทำนายมีความแตกต่างจากกลุ่มประชากรหลัก

ค่าผิดปกติ (Outlier)

- Data errors: ค่าผิดพลาดจากการเก็บข้อมูล
- Normal variance in the data: 0.26% นอก 3 SD ของการกระจายแบบปกติ
- Data from other distribution classes: ค่าที่นอกเหนือจากกลุ่ม เช่นข้อมูลการเข้าถึงหน้าเว็บจากผู้ใช้ แต่พบว่าผู้ใช้ IP เดียว หลายแสนครั้งต่อวัน
- Distributional assumptions: ค่าที่ผิดปกติจากสมมติฐาน เช่นยอดขายสูงขึ้นหนึ่งหมื่นเท่า ในวันเดียว

เทคนิคการตรวจจับความผิดปกติ

- ใช้วิธีทางสถิติ พิจารณาการกระจายตัว



เทคนิคการตรวจจับความผิดปกติ

- ใช้หลักการ วิทยาการข้อมูล
 - **Distance-based:** เช่นหลักการเพื่อนบ้าน k-NN
 - **Density-based:** อิงความถี่ ความหนาแน่นประชากร
 - Distribution-based
 - Clustering
 - Classification techniques




FIGURE 13.2
Distance-based outlier.

DISTANCE-BASED OUTLIER DETECTION




FIGURE 13.3
Dataset with outliers.

แบบจำลอง K-nearest neighbor

Distance-based: k-NN ใช้การคำนวณคะแนนระยะทาง โดยกำหนดค่าจำนวนเพื่อนบ้าน k






Figure 2.24 K-nearest neighbor techniques look at the k -nearest point to make a prediction.




k = 1




k = 5

Detect Outlier Operator (Distances)




PCA

กระบวนการทางสถิติที่แปลงฟีเจอร์ของข้อมูลจริง (Transform data) ให้กลายเป็นฟีเจอร์ใหม่ที่ไม่มีความสัมพันธ์ในเชิงเส้น (linearly uncorrelated) ซึ่งถูกเรียกว่า **principal components**



ใช้ PC1 เป็นตัวแทน X, Y เนื่องจากอธิบายข้อมูลได้ดีกว่า PC2 → ลดรูปได้จาก 2 ฟีเจอร์เหลือ 1 ฟีเจอร์

Proportion of Variance



PCA (PCA)

Component	Standard Deviation	Proportion of Variance	Cumulative Variance
PC 1	1.706	0.728	0.728
PC 2	0.960	0.230	0.958
PC 3	0.384	0.037	0.995
PC 4	0.144	0.005	1.000

DENSITY-BASED OUTLIER DETECTION

- ینگค่าความหนาแน่น ซึ่งแปรผันตามความหนาแน่นข้อมูลกับระยะทาง






FIGURE 13.7

Outlier detection based on distance and propensity.


Detect Outlier (Densities)






Detect Outlier (LOCAL OUTLIER FACTOR: LOF)

- พิจารณาเป็นคะแนน





Ref

